Задача I.6.3

Условие: Пусть y^* — приближение к корню уравнения $f(y) = 0$. Вывести приближенное равенство $y - y^* \approx -\frac{f(y^*)}{f'(y^*)}$.

Решение:

Пусть y — точный корень уравнения $f(y) = 0$, а y^* — его некоторое приближенное значение. Предположим, что функция $f(y)$ является достаточно гладкой (непрерывно дифференцируемой) в окрестности точки y^*.

Разложим функцию $f(y)$ в ряд Тейлора в окрестности точки y^*:

$$f(y) = f(y^*) + f'(y^*)(y - y^*) + \frac{f''(\xi)}{2}(y - y^*)^2, \tag{1}$$

где ξ — некоторая точка, лежащая между y и y^*.

Так как y является точным корнем уравнения, выполняется равенство $f(y) = 0$. Подставим его в разложение:

$$0 = f(y^*) + f'(y^*)(y - y^*) + \frac{f''(\xi)}{2}(y - y^*)^2. \tag{2}$$

Поскольку y^* выбрано как приближение к корню, разность $(y - y^*)$ является малой величиной. Следовательно, квадратом этой разности $(y - y^*)^2$ (членом второго порядка малости) можно пренебречь по сравнению с линейным членом. Отбрасывая остаточный член, получаем приближенное линейное соотношение:

$$0 \approx f(y^*) + f'(y^*)(y - y^*). \tag{3}$$

Выразим из этого равенства искомую разность $y - y^*$:

$$f'(y^*)(y - y^*) \approx -f(y^*), \tag{4}$$

$$y - y^* \approx -\frac{f(y^*)}{f'(y^*)}. \tag{5}$$

Замечание: Полученное приближенное равенство имеет фундаментальное значение в вычислительной математике. Оно показывает, что поправка $\Delta y = y - y^*$, которую необходимо добавить к приближению y^*, чтобы получить точный корень, пропорциональна значению функции в этой точке и обратно пропорциональна её производной. Именно эта формула лежит в основе итерационного метода Ньютона (метода касательных) для численного решения нелинейных уравнений.

Задача I.8.11

Условие: Найти линейную оценку погрешности для функции $u = \ln t$, если заданы точка приближения $t^* = 1$, значение функции u^* в этой точке и погрешность $\Delta t^* = 0{,}1$.

Решение:

1. Исходные данные

Задана функция:

$$u(t) = \ln t. \tag{6}$$

Приближённое значение аргумента:

$$t^* = 1. \tag{7}$$

Абсолютная погрешность аргумента:

$$\Delta t^* = 0{,}1. \tag{8}$$

Значение функции в точке приближения:

$$u^* = u(t^*) = \ln 1 = 0. \tag{9}$$

2. Формула линейной оценки погрешности

Если функция $u(t)$ дифференцируема в окрестности точки t^*, то абсолютная погрешность функции Δu^* оценивается по формуле:

$$\Delta u^* \approx \left| \frac{du}{dt} \Big|_{t=t^*} \right| \cdot \Delta t^*. \tag{10}$$

Эта формула следует из разложения функции в ряд Тейлора в окрестности точки t^* с отбрасыванием членов второго и высших порядков малости (линеаризация).

3. Вычисление производной

Найдём производную функции $u(t) = \ln t$:

$$\frac{du}{dt} = \frac{1}{t}. \tag{11}$$

Вычислим значение производной в точке $t^* = 1$:

$$\frac{du}{dt}\Big|_{t=1} = \frac{1}{1} = 1. \tag{12}$$

4. Линейная оценка абсолютной погрешности

Подставим найденные значения в формулу (10):

$$\Delta u^* \approx |1| \cdot 0{,}1 = 0{,}1. \tag{13}$$

Таким образом, линейная оценка абсолютной погрешности функции $u = \ln t$ при $t^* = 1$ и $\Delta t^* = 0{,}1$ равна:

$$\boxed{\Delta u^* \approx 0{,}1.} \tag{14}$$

5. Относительная погрешность

Относительная погрешность функции определяется как:

$$\delta u^* = \frac{\Delta u^*}{|u^*|}. \tag{15}$$

Однако в нашем случае $u^* = \ln 1 = 0$, поэтому относительная погрешность **не определена** (формально стремится к бесконечности). Это характерная ситуация для функций, обращающихся в нуль в точке приближения: абсолютная погрешность может быть конечной, но относительная теряет смысл.

6. Проверка результата

Для контроля вычислим точные значения функции на границах интервала неопределённости аргумента $t \in [t^* - \Delta t^*, t^* + \Delta t^*] = [0{,}9; 1{,}1]$:

$$u(0{,}9) = \ln 0{,}9 \approx -0{,}1054, \tag{16}$$

$$u(1{,}1) = \ln 1{,}1 \approx 0{,}0953. \tag{17}$$

Максимальное отклонение от $u^* = 0$:

$$\max\big(|u(0{,}9) - 0|, |u(1{,}1) - 0|\big) = \max(0{,}1054; 0{,}0953) \approx 0{,}1054. \tag{18}$$

Линейная оценка $\Delta u^* \approx 0{,}1$ близка к точному значению 0,1054, что подтверждает корректность применения формулы (10). Небольшое расхождение объясняется отброшенными членами высшего порядка малости в разложении Тейлора.

Задача I.8.33

Условие: Для вычисления первой производной функции $f(x)$ в точке $x+h$ используется формула $(f(x+2h)-f(x-2h))/(4h)$.

а) Каков порядок аппроксимации этой формулы?

б) Найти оптимальный шаг дифференцирования по этой формуле в произвольной точке для четырежды дифференцируемой функции.

в) Оценить его численное значение для функции $f(x)=\cos(x+\pi/4)$ в случае использования IEEE-арифметики одинарной и двойной точности.

Решение:

а) Порядок аппроксимации

Нам нужно оценить погрешность формулы:

$$f'(x+h) \approx \frac{f(x+2h)-f(x-2h)}{4h}. \tag{19}$$

Разложим $f(x+2h)$ и $f(x-2h)$ в ряд Тейлора в точке $x+h$. Заметим, что:

$$x+2h = (x+h)+h, \tag{20}$$
$$x-2h = (x+h)-3h. \tag{21}$$

Тогда разложения имеют вид:

$$f(x+2h) = f(x+h) + hf'(x+h) + \frac{h^2}{2}f''(x+h) + \frac{h^3}{6}f'''(x+h) + O(h^4), \tag{22}$$
$$f(x-2h) = f(x+h) - 3hf'(x+h) + \frac{9h^2}{2}f''(x+h) - \frac{27h^3}{6}f'''(x+h) + O(h^4). \tag{23}$$

Вычислим разность:

$$\begin{aligned} f(x+2h)-f(x-2h) &= 4hf'(x+h) - 4h^2f''(x+h) + \frac{28h^3}{6}f'''(x+h) + O(h^4) \\ &= 4hf'(x+h) - 4h^2f''(x+h) + \frac{14h^3}{3}f'''(x+h) + O(h^4). \end{aligned} \tag{24}$$

Подставим в формулу (19):

$$\frac{f(x+2h)-f(x-2h)}{4h} = f'(x+h) - hf''(x+h) + \frac{7h^2}{6}f'''(x+h) + O(h^3). \tag{25}$$

Погрешность метода (усечение ряда Тейлора):

$$E_{\text{мет}} = \left|\frac{f(x+2h)-f(x-2h)}{4h} - f'(x+h)\right| = \left|-hf''(x+h) + O(h^2)\right| \approx h|f''(x+h)|. \tag{26}$$

Поскольку главный член погрешности пропорционален h^1, **порядок аппроксимации формулы равен 1** (первый порядок).

Замечание: Это отличается от стандартной формулы центральной разности $(f(x+h)-f(x-h))/(2h)$, которая имеет второй порядок аппроксимации. В нашей формуле точки $x+2h$ и $x-2h$ симметричны относительно x, а не относительно $x+h$, что приводит к появлению члена с $f''(x+h)$ и снижению порядка точности.

б) Оптимальный шаг дифференцирования

Полная погрешность численного дифференцирования складывается из двух составляющих:

1. **Погрешность метода** (усечение ряда Тейлора): $E_{\text{мет}} \approx h|f''(x+h)|$.
2. **Погрешность вычислений** (ошибки округления при вычислении f): при вычислении разности $f(x+2h)-f(x-2h)$ каждое значение функции вычисляется с относительной погрешностью $\varepsilon_{\text{маш}}$. Абсолютная погрешность разности порядка $2\varepsilon_{\text{маш}}|f|$, а после деления на $4h$ получаем:

$$E_{\text{выч}} \approx \frac{2\varepsilon_{\text{маш}}|f(x+h)|}{4h} = \frac{\varepsilon_{\text{маш}}|f(x+h)|}{2h}. \tag{27}$$

Полная погрешность:

$$E_{\text{полн}} \approx h|f''(x+h)| + \frac{\varepsilon_{\text{маш}}|f(x+h)|}{2h}. \tag{28}$$

Найдём оптимальный шаг h_{opt}, минимизирующий $E_{\text{полн}}$. Продифференцируем (28) по h и приравняем к нулю:

$$\frac{dE_{\text{полн}}}{dh} = |f''(x+h)| - \frac{\varepsilon_{\text{маш}}|f(x+h)|}{2h^2} = 0. \tag{29}$$

Отсюда:

$$h^2 = \frac{\varepsilon_{\text{маш}}|f(x+h)|}{2|f''(x+h)|}, \tag{30}$$

$$\boxed{h_{\text{opt}} = \sqrt{\frac{\varepsilon_{\text{маш}}|f(x+h)|}{2|f''(x+h)|}}.} \tag{31}$$

Замечание: Сравните с формулой оптимального шага для центральной разности второго порядка: там $h_{\text{opt}} \sim \varepsilon_{\text{маш}}^{1/3}$, а у нас $h_{\text{opt}} \sim \varepsilon_{\text{маш}}^{1/2}$. Это следствие более низкого порядка аппроксимации.

в) Численная оценка для $f(x) = \cos(x + \pi/4)$

Найдём производные:

$$f(x) = \cos(x+\pi/4), \tag{32}$$
$$f'(x) = -\sin(x+\pi/4), \tag{33}$$
$$f''(x) = -\cos(x+\pi/4). \tag{34}$$

В точке $x + h$:

$$f(x+h) = \cos(x+h+\pi/4), \tag{35}$$
$$f''(x+h) = -\cos(x+h+\pi/4). \tag{36}$$

Отношение:

$$\frac{|f(x+h)|}{|f''(x+h)|} = \frac{|\cos(x+h+\pi/4)|}{|\cos(x+h+\pi/4)|} = 1 \quad (\text{при } \cos(x+h+\pi/4) \neq 0). \tag{37}$$

Подставим в формулу (31):

$$h_{\text{opt}} = \sqrt{\frac{\varepsilon_{\text{маш}}}{2}}. \tag{38}$$

Для IEEE-арифметики одинарной точности ($\varepsilon_{\text{маш}} \approx 6{,}0 \cdot 10^{-8}$):

$$h_{\text{opt}}^{(\text{float})} = \sqrt{\frac{6{,}0 \cdot 10^{-8}}{2}} = \sqrt{3{,}0 \cdot 10^{-8}} \approx 1{,}7 \cdot 10^{-4}. \tag{39}$$

Для IEEE-арифметики двойной точности ($\varepsilon_{\text{маш}} \approx 1{,}1 \cdot 10^{-16}$):

$$h_{\text{opt}}^{(\text{double})} = \sqrt{\frac{1{,}1 \cdot 10^{-16}}{2}} = \sqrt{5{,}5 \cdot 10^{-17}} \approx 7{,}4 \cdot 10^{-9}. \tag{40}$$

Итог

- Порядок аппроксимации формулы $(f(x+2h) - f(x-2h))/(4h)$ для вычисления $f'(x+h)$ равен **1** (первый порядок).
- Оптимальный шаг: $h_{\text{opt}} = \sqrt{\varepsilon_{\text{маш}}|f|/(2|f''|)}$.
- Для $f(x) = \cos(x+\pi/4)$: $h_{\text{opt}} \approx 1{,}7 \cdot 10^{-4}$ (одинарная точность) и $h_{\text{opt}} \approx 7{,}4 \cdot 10^{-9}$ (двойная точность).

Задача II.7.39

Условие: Доказать, что для систем линейных уравнений второго порядка ($n = 2$) методы Якоби и Гаусса–Зейделя сходятся и расходятся одновременно.

Решение:

1. Постановка задачи

Рассмотрим систему линейных уравнений $\mathbf{A}\mathbf{x} = \mathbf{b}$, где $\mathbf{A}$ — матрица размера 2×2:

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} b_1 \\ b_2 \end{pmatrix}. \tag{41}$$

Предполагаем, что диагональные элементы ненулевые: $a_{11} \neq 0$, $a_{22} \neq 0$.

Разложим матрицу $\mathbf{A}$ в виде:

$$\mathbf{A} = \mathbf{D} - \mathbf{L} - \mathbf{U}, \tag{42}$$

где $\mathbf{D}$ — диагональная часть, $-\mathbf{L}$ — строго нижняя треугольная, $-\mathbf{U}$ — строго верхняя треугольная:

$$\mathbf{D} = \begin{pmatrix} a_{11} & 0 \\ 0 & a_{22} \end{pmatrix}, \quad \mathbf{L} = \begin{pmatrix} 0 & 0 \\ -a_{21} & 0 \end{pmatrix}, \quad \mathbf{U} = \begin{pmatrix} 0 & -a_{12} \\ 0 & 0 \end{pmatrix}. \tag{43}$$

2. Метод Якоби

Итерационная матрица метода Якоби имеет вид:

$$\mathbf{B}_J = \mathbf{D}^{-1}(\mathbf{L} + \mathbf{U}). \tag{44}$$

Вычислим её явно:

$$\mathbf{B}_J = \begin{pmatrix} 1/a_{11} & 0 \\ 0 & 1/a_{22} \end{pmatrix} \begin{pmatrix} 0 & -a_{12} \\ -a_{21} & 0 \end{pmatrix} = \begin{pmatrix} 0 & -a_{12}/a_{11} \\ -a_{21}/a_{22} & 0 \end{pmatrix}. \tag{45}$$

Найдём собственные значения $\mathbf{B}_J$ из характеристического уравнения $\det(\mathbf{B}_J - \lambda \mathbf{I}) = 0$:

$$\det \begin{pmatrix} -\lambda & -a_{12}/a_{11} \\ -a_{21}/a_{22} & -\lambda \end{pmatrix} = \lambda^2 - \frac{a_{12}a_{21}}{a_{11}a_{22}} = 0. \tag{46}$$

Отсюда собственные значения:

$$\lambda_{1,2}^{(J)} = \pm\sqrt{\frac{a_{12}a_{21}}{a_{11}a_{22}}}. \tag{47}$$

Спектральный радиус матрицы Якоби:

$$\rho(\mathbf{B}_J) = \sqrt{\left|\frac{a_{12}a_{21}}{a_{11}a_{22}}\right|}. \tag{48}$$

Метод Якоби сходится тогда и только тогда, когда $\rho(\mathbf{B}_J) < 1$.

3. Метод Гаусса–Зейделя

Итерационная матрица метода Гаусса–Зейделя:

$$\mathbf{B}_{GS} = (\mathbf{D} - \mathbf{L})^{-1}\mathbf{U}. \tag{49}$$

Сначала найдём $(\mathbf{D} - \mathbf{L})^{-1}$:

$$\mathbf{D} - \mathbf{L} = \begin{pmatrix} a_{11} & 0 \\ a_{21} & a_{22} \end{pmatrix}, \quad (\mathbf{D} - \mathbf{L})^{-1} = \begin{pmatrix} 1/a_{11} & 0 \\ -a_{21}/(a_{11}a_{22}) & 1/a_{22} \end{pmatrix}. \tag{50}$$

Теперь вычислим $\mathbf{B}_{GS}$:

$$\mathbf{B}_{GS} = \begin{pmatrix} 1/a_{11} & 0 \\ -a_{21}/(a_{11}a_{22}) & 1/a_{22} \end{pmatrix} \begin{pmatrix} 0 & -a_{12} \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & -a_{12}/a_{11} \\ 0 & a_{12}a_{21}/(a_{11}a_{22}) \end{pmatrix}. \tag{51}$$

Матрица $\mathbf{B}_{GS}$ является верхнетреугольной, поэтому её собственные значения равны диагональным элементам:

$$\lambda_1^{(GS)} = 0, \quad \lambda_2^{(GS)} = \frac{a_{12}a_{21}}{a_{11}a_{22}}. \tag{52}$$

Спектральный радиус матрицы Гаусса–Зейделя:

$$\rho(\mathbf{B}_{GS}) = \left|\frac{a_{12}a_{21}}{a_{11}a_{22}}\right|. \tag{53}$$

4. Сравнение спектральных радиусов

Сравнивая формулы (48) и (53), получаем фундаментальное соотношение для систем второго порядка:

$$\boxed{\rho(\mathbf{B}_{GS}) = [\rho(\mathbf{B}_J)]^2 .} \tag{54}$$

5. Доказательство одновременности сходимости и расходимости

Из соотношения (54) непосредственно следуют оба утверждения:

Сходимость:

$$\rho(\mathbf{B}_J) < 1 \iff [\rho(\mathbf{B}_J)]^2 < 1 \iff \rho(\mathbf{B}_{GS}) < 1. \tag{55}$$

То есть метод Якоби сходится тогда и только тогда, когда сходится метод Гаусса–Зейделя.

Расходимость:

$$\rho(\mathbf{B}_J) > 1 \iff [\rho(\mathbf{B}_J)]^2 > 1 \iff \rho(\mathbf{B}_{GS}) > 1. \tag{56}$$

То есть метод Якоби расходится тогда и только тогда, когда расходится метод Гаусса–Зейделя.

Граничный случай $\rho(\mathbf{B}_J) = 1$ также совпадает: $\rho(\mathbf{B}_{GS}) = 1$.

6. Замечание о скорости сходимости

Из соотношения $\rho(\mathbf{B}_{GS}) = [\rho(\mathbf{B}_J)]^2$ следует важный практический вывод: если оба метода сходятся, то метод Гаусса–Зейделя сходится **примерно в два раза быстрее** метода Якоби (поскольку число итераций, необходимое для достижения заданной точности, обратно пропорционально $-\ln \rho$).

Важно: данное свойство (одновременность сходимости) является специфическим для систем размера $n = 2$. Для $n \geqslant 3$ существуют примеры, когда один из методов сходится, а другой — расходится.

Задача II.9.2 (пункт б)

Условие: Дана система линейных алгебраических уравнений $\mathbf{Ax} = \mathbf{b}$. Оценить максимально точную относительную погрешность $\|\Delta\mathbf{x}\|/\|\mathbf{x}\|$ в заданной норме. Найти вектор ошибки $\Delta\mathbf{b}$, на котором эта оценка достигается. При каком $\Delta\mathbf{b}$ относительная ошибка $\|\Delta\mathbf{x}\|/\|\mathbf{x}\|$ будет минимальной? Найти её.

$$\mathbf{A} = \begin{pmatrix} 101 & -110 \\ -110 & 122 \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} 92 \\ -98 \end{pmatrix}, \quad \frac{\|\Delta\mathbf{b}\|}{\|\mathbf{b}\|} = 0{,}01, \quad \|\mathbf{x}\| = \sum_i |x_i|.$$

Примечание: в условии норма обозначена как $\|\cdot\|_2$, но по формуле $\sum_i |x_i|$ это стандартная норма $\|\cdot\|_1$ (сумма модулей компонент). Будем следовать обозначению условия, но помнить, что работаем с суммой модулей.

Решение:

1. Решение системы $\mathbf{Ax} = \mathbf{b}$

Найдём определитель матрицы $\mathbf{A}$:

$$\det(\mathbf{A}) = 101 \cdot 122 - (-110) \cdot (-110) = 12322 - 12100 = 222. \tag{57}$$

Обратная матрица:

$$\mathbf{A}^{-1} = \frac{1}{222} \begin{pmatrix} 122 & 110 \\ 110 & 101 \end{pmatrix}. \tag{58}$$

Решение системы $\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}$:

$$\mathbf{x} = \frac{1}{222} \begin{pmatrix} 122 & 110 \\ 110 & 101 \end{pmatrix} \begin{pmatrix} 92 \\ -98 \end{pmatrix} = \frac{1}{222} \begin{pmatrix} 11224 - 10780 \\ 10120 - 9898 \end{pmatrix} = \frac{1}{222} \begin{pmatrix} 444 \\ 222 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}. \tag{59}$$

Итак, $\mathbf{x} = (2, 1)^T$.

2. Вычисление норм

Норма вектора $\mathbf{x}$ (сумма модулей компонент):

$$\|\mathbf{x}\| = |2| + |1| = 3. \tag{60}$$

Норма вектора $\mathbf{b}$:

$$\|\mathbf{b}\| = |92| + |-98| = 190. \tag{61}$$

Абсолютная погрешность правой части:

$$\|\Delta\mathbf{b}\| = 0{,}01 \cdot \|\mathbf{b}\| = 0{,}01 \cdot 190 = 1{,}9. \tag{62}$$

Норма матрицы $\mathbf{A}$ (максимум сумм модулей элементов по столбцам):

$$\|\mathbf{A}\| = \max\big(|101| + |-110|,\ |-110| + |122|\big) = \max(211,\ 232) = 232. \tag{63}$$

Норма обратной матрицы:

$$\|\mathbf{A}^{-1}\| = \frac{1}{222}\max\big(|122| + |110|,\ |110| + |101|\big) = \frac{1}{222}\max(232,\ 211) = \frac{232}{222} = \frac{116}{111}. \tag{64}$$

3. Число обусловленности и теоретическая оценка погрешности

Число обусловленности матрицы $\mathbf{A}$:

$$\operatorname{cond}(\mathbf{A}) = \|\mathbf{A}\| \cdot \|\mathbf{A}^{-1}\| = 232 \cdot \frac{232}{222} = \frac{53824}{222} = \frac{26912}{111} \approx 242{,}45. \tag{65}$$

Важное замечание о смысле этой оценки. Стандартная теорема даёт *верхнюю границу* относительной погрешности:

$$\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} \leqslant \operatorname{cond}(\mathbf{A}) \cdot \frac{\|\Delta\mathbf{b}\|}{\|\mathbf{b}\|} = \frac{26912}{111} \cdot 0{,}01 \approx 2{,}4245. \tag{66}$$

Эта оценка **достижима в худшем случае** — когда одновременно и $\mathbf{b}$, и $\Delta\mathbf{b}$ направлены "наихудшим" образом. Однако в нашей задаче вектор $\mathbf{b}$ *фиксирован*, поэтому реальная максимальная погрешность будет меньше. Найдём её точно.

4. Точный максимум погрешности при фиксированном b

Из уравнения $\mathbf{A}(\mathbf{x} + \Delta\mathbf{x}) = \mathbf{b} + \Delta\mathbf{b}$ следует $\Delta\mathbf{x} = \mathbf{A}^{-1}\Delta\mathbf{b}$. Поскольку $\mathbf{x}$ фиксирован, задача сводится к максимизации $\|\mathbf{A}^{-1}\Delta\mathbf{b}\|$ при условии $\|\Delta\mathbf{b}\| = 1{,}9$.

Как найти максимум $\|\mathbf{A}^{-1}\Delta\mathbf{b}\|$? В норме $\|\cdot\| = \sum|x_i|$ максимум $\|\mathbf{M}\mathbf{y}\|/\|\mathbf{y}\|$ равен $\|\mathbf{M}\|$ и достигается, когда $\mathbf{y}$ — это базисный вектор $\mathbf{e}_j$, соответствующий столбцу матрицы $\mathbf{M}$ с наибольшей суммой модулей элементов.

Применяем к $\mathbf{M} = \mathbf{A}^{-1}$:

- Первый столбец $\mathbf{A}^{-1}$: сумма модулей $= (122 + 110)/222 = 232/222$.
- Второй столбец $\mathbf{A}^{-1}$: сумма модулей $= (110 + 101)/222 = 211/222$.

Первый столбец даёт максимум, поэтому оптимальное направление: $\Delta\mathbf{b} = \pm 1{,}9 \cdot \mathbf{e}_1 = \pm(1{,}9;\ 0)^T$.

Проверка. При $\Delta\mathbf{b} = (1{,}9;\ 0)^T$:

$$\Delta\mathbf{x} = \mathbf{A}^{-1}\Delta\mathbf{b} = \frac{1{,}9}{222}\begin{pmatrix}122\\110\end{pmatrix} \approx \begin{pmatrix}1{,}044\\0{,}941\end{pmatrix}. \tag{67}$$

$$\|\Delta\mathbf{x}\| = \frac{1{,}9}{222}(122 + 110) = \frac{1{,}9 \cdot 232}{222} \approx 1{,}986. \tag{68}$$

$$\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} = \frac{1{,}986}{3} \approx 0{,}662. \tag{69}$$

Итог по максимуму:

$$\boxed{\max_{\|\Delta\mathbf{b}\|=1{,}9} \frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} = \frac{\|\mathbf{A}^{-1}\| \cdot \|\Delta\mathbf{b}\|}{\|\mathbf{x}\|} = \frac{232 \cdot 1{,}9}{222 \cdot 3} = \frac{440{,}8}{666} \approx 0{,}662.} \tag{70}$$

Оценка достигается на $\Delta\mathbf{b} = \pm(1{,}9;\ 0)^T$.

Почему оценка через $\operatorname{cond}(\mathbf{A}) \approx 2{,}42$ не достигается? Потому что она предполагает "худший" $\mathbf{b}$, а наш $\mathbf{b} = (92;\ -98)^T$ не является таким. Отношение $\|\mathbf{b}\|/\|\mathbf{x}\| = 190/3 \approx 63{,}3$, тогда как для "худшего" $\mathbf{b}$ это отношение было бы равно $\|\mathbf{A}\| = 232$.

5. Минимальная погрешность

Тривиальный случай: при $\Delta\mathbf{b} = \mathbf{0}$ погрешность равна нулю:

$$\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} = 0. \tag{71}$$

Нетривиальный случай: найдём минимум $\|\Delta\mathbf{x}\|/\|\mathbf{x}\|$ при фиксированном $\|\Delta\mathbf{b}\| = 1{,}9$, т. е. минимум $\|\mathbf{A}^{-1}\Delta\mathbf{b}\|/\|\Delta\mathbf{b}\|$.

Ключевое свойство подчинённых норм: для любой обратимой матрицы $\mathbf{M}$

$$\min_{\mathbf{y}\neq 0} \frac{\|\mathbf{M}\mathbf{y}\|}{\|\mathbf{y}\|} = \frac{1}{\|\mathbf{M}^{-1}\|}. \tag{72}$$

Доказательство: из $\mathbf{y} = \mathbf{M}^{-1}(\mathbf{M}\mathbf{y})$ и неравенства $\|\mathbf{y}\| \leqslant \|\mathbf{M}^{-1}\| \cdot \|\mathbf{M}\mathbf{y}\|$ следует $\|\mathbf{M}\mathbf{y}\|/\|\mathbf{y}\| \geqslant 1/\|\mathbf{M}^{-1}\|$. Равенство достигается на "худшем" векторе для $\mathbf{M}^{-1}$.

Применяем к $\mathbf{M} = \mathbf{A}^{-1}$:

$$\min \frac{\|\mathbf{A}^{-1}\Delta\mathbf{b}\|}{\|\Delta\mathbf{b}\|} = \frac{1}{\|(\mathbf{A}^{-1})^{-1}\|} = \frac{1}{\|\mathbf{A}\|} = \frac{1}{232}. \tag{73}$$

На каком $\Delta\mathbf{b}$ достигается минимум? На векторе, где $\mathbf{A}$ достигает своей нормы, т. е. на столбце $\mathbf{A}$ с максимальной суммой модулей элементов. Это второй столбец: $(-110;\, 122)^T$ (сумма модулей $= 232 = \|\mathbf{A}\|$).

Нормируем: $\|\Delta\mathbf{b}\| = 1{,}9$, поэтому

$$\Delta\mathbf{b}_{\min} = \frac{1{,}9}{232}\begin{pmatrix}-110\\122\end{pmatrix} \approx \begin{pmatrix}-0{,}901\\1{,}000\end{pmatrix}. \tag{74}$$

Проверка. Вычислим $\mathbf{A}^{-1}\Delta\mathbf{b}_{\min}$:

$$\mathbf{A}^{-1}\begin{pmatrix}-110\\122\end{pmatrix} = \frac{1}{222}\begin{pmatrix}122\cdot(-110)+110\cdot 122\\110\cdot(-110)+101\cdot 122\end{pmatrix} = \frac{1}{222}\begin{pmatrix}0\\222\end{pmatrix} = \begin{pmatrix}0\\1\end{pmatrix}. \tag{75}$$

Значит,

$$\Delta\mathbf{x} = \frac{1{,}9}{232}\begin{pmatrix}0\\1\end{pmatrix}, \quad \|\Delta\mathbf{x}\| = \frac{1{,}9}{232} \approx 0{,}00819. \tag{76}$$

$$\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} = \frac{1{,}9}{232\cdot 3} = \frac{1{,}9}{696} \approx 0{,}00273. \tag{77}$$

Итог по минимуму:

$$\boxed{\min_{\|\Delta\mathbf{b}\|=1{,}9} \frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} = \frac{\|\Delta\mathbf{b}\|}{\|\mathbf{A}\|\cdot\|\mathbf{x}\|} = \frac{1{,}9}{232\cdot 3} \approx 0{,}00273 \quad (\approx 0{,}27\%).} \tag{78}$$

Минимум достигается на $\Delta\mathbf{b} \propto (-110;\, 122)^T$.

Итог

- Решение системы: $\mathbf{x} = (2,\, 1)^T$.
- Теоретическая оценка через $\mathrm{cond}(\mathbf{A})$: $\|\Delta\mathbf{x}\|/\|\mathbf{x}\| \leqslant 2{,}42$ ($\approx 242\%$) — достижима только при "худшем" $\mathbf{b}$.
- Реальный максимум при данном $\mathbf{b}$: $\approx 0{,}662$ ($\approx 66\%$), достигается на $\Delta\mathbf{b} = \pm(1{,}9;\, 0)^T$.
- Минимальная ненулевая погрешность: $\approx 0{,}00273$ ($\approx 0{,}27\%$), достигается на $\Delta\mathbf{b} \propto (-110;\, 122)^T$.

Условие: Дана система линейных алгебраических уравнений $\mathbf{A}\mathbf{x} = \mathbf{b}$. Оценить максимально точную относительную погрешность $\|\Delta\mathbf{x}\|/\|\mathbf{x}\|$ в заданной норме. Найти вектор ошибки $\Delta\mathbf{b}$, на котором эта оценка достигается. При каком $\Delta\mathbf{b}$ относительная ошибка $\|\Delta\mathbf{x}\|/\|\mathbf{x}\|$ будет минимальной? Найти её.

$$\mathbf{A} = \begin{pmatrix}101 & -110\\-110 & 122\end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix}92\\-98\end{pmatrix}, \quad \frac{\|\Delta\mathbf{b}\|_2}{\|\mathbf{b}\|_2} = 0{,}01, \quad \|\mathbf{x}\|_2 = \sum_i |x_i|.$$

Решение:

1. Решение системы $\mathbf{Ax} = \mathbf{b}$

Найдём определитель матрицы $\mathbf{A}$:

$$\det(\mathbf{A}) = 101 \cdot 122 - (-110) \cdot (-110) = 12322 - 12100 = 222. \tag{79}$$

Обратная матрица:

$$\mathbf{A}^{-1} = \frac{1}{222} \begin{pmatrix} 122 & 110 \\ 110 & 101 \end{pmatrix}. \tag{80}$$

Решение системы $\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}$:

$$\mathbf{x} = \frac{1}{222} \begin{pmatrix} 122 & 110 \\ 110 & 101 \end{pmatrix} \begin{pmatrix} 92 \\ -98 \end{pmatrix} = \frac{1}{222} \begin{pmatrix} 122 \cdot 92 + 110 \cdot (-98) \\ 110 \cdot 92 + 101 \cdot (-98) \end{pmatrix} = \frac{1}{222} \begin{pmatrix} 11224 - 10780 \\ 10120 - 9898 \end{pmatrix} = \frac{1}{222} \begin{pmatrix} 444 \\ 222 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}. \tag{81}$$

Итак, $\mathbf{x} = (2, 1)^T$.

2. Вычисление норм

Согласно условию, используется норма $\|\mathbf{x}\|_2 = \sum_i |x_i|$ (сумма модулей компонент):

$$\|\mathbf{x}\|_2 = |2| + |1| = 3. \tag{82}$$

Норма вектора $\mathbf{b}$:

$$\|\mathbf{b}\|_2 = |92| + |-98| = 190. \tag{83}$$

Норма матрицы $\mathbf{A}$ (в той же норме, что и векторы — максимум сумм модулей элементов по столбцам):

$$\|\mathbf{A}\|_2 = \max_j \sum_i |a_{ij}| = \max(|101| + |-110|, |-110| + |122|) = \max(211, 232) = 232. \tag{84}$$

Норма обратной матрицы:

$$\|\mathbf{A}^{-1}\|_2 = \frac{1}{222} \max(|122| + |110|, |110| + |101|) = \frac{1}{222} \max(232, 211) = \frac{232}{222} = \frac{116}{111}. \tag{85}$$

3. Число обусловленности и оценка погрешности

Число обусловленности матрицы $\mathbf{A}$:

$$\mathrm{cond}(\mathbf{A}) = \|\mathbf{A}\|_2 \cdot \|\mathbf{A}^{-1}\|_2 = 232 \cdot \frac{232}{222} = \frac{53824}{222} = \frac{26912}{111} \approx 242{,}45. \tag{86}$$

Максимально точная оценка относительной погрешности:

$$\frac{\|\Delta\mathbf{x}\|_2}{\|\mathbf{x}\|_2} \leqslant \mathrm{cond}(\mathbf{A}) \cdot \frac{\|\Delta\mathbf{b}\|_2}{\|\mathbf{b}\|_2} = \frac{26912}{111} \cdot 0{,}01 = \frac{269{,}12}{111} \approx 2{,}4245. \tag{87}$$

Таким образом, относительная погрешность решения может достигать $\approx 242\%$, что свидетельствует о плохой обусловленности системы.

4. Вектор $\Delta\mathbf{b}$, на котором оценка достигается

Оценка достигается, когда $\Delta\mathbf{b}$ направлен так, чтобы максимизировать $\|\mathbf{A}^{-1}\Delta\mathbf{b}\|_2$ при заданном $\|\Delta\mathbf{b}\|_2$.

Для нормы $\|\cdot\|_2 = \sum |x_i|$ максимум $\|\mathbf{A}^{-1}\Delta\mathbf{b}\|_2$ достигается, когда $\Delta\mathbf{b}$ пропорционален столбцу матрицы $\mathbf{A}^{-1}$ с максимальной суммой модулей элементов.

Из вычислений выше, второй столбец $\mathbf{A}^{-1}$ имеет большую сумму: $(110+101)/222 = 211/222$, а первый: $(122 + 110)/222 = 232/222$.

Следовательно, максимум достигается на первом столбце:

$$\Delta\mathbf{b} = \pm\|\Delta\mathbf{b}\|_2 \cdot \mathbf{e}_1 = \pm 0{,}01 \cdot 190 \cdot \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \pm \begin{pmatrix} 1{,}9 \\ 0 \end{pmatrix}. \tag{88}$$

Проверка: при $\Delta\mathbf{b} = (1{,}9, 0)^T$:

$$\Delta\mathbf{x} = \mathbf{A}^{-1}\Delta\mathbf{b} = \frac{1}{222} \begin{pmatrix} 122 & 110 \\ 110 & 101 \end{pmatrix} \begin{pmatrix} 1{,}9 \\ 0 \end{pmatrix} = \frac{1}{222} \begin{pmatrix} 231{,}8 \\ 209 \end{pmatrix} \approx \begin{pmatrix} 1{,}044 \\ 0{,}941 \end{pmatrix}. \tag{89}$$

$$\|\Delta\mathbf{x}\|_2 = 1{,}044 + 0{,}941 = 1{,}985. \tag{90}$$

$$\frac{\|\Delta\mathbf{x}\|_2}{\|\mathbf{x}\|_2} = \frac{1{,}985}{3} \approx 0{,}662. \tag{91}$$

Это меньше теоретического максимума 2,4245, потому что точное достижение оценки требует также оптимального направления $\mathbf{x}$, которое в нашей задаче фиксировано.

5. Минимальная относительная ошибка

Минимальная относительная ошибка $\|\Delta\mathbf{x}\|_2/\|\mathbf{x}\|_2$ достигается при $\Delta\mathbf{b} = \mathbf{0}$ и равна:

$$\boxed{\frac{\|\Delta\mathbf{x}\|_2}{\|\mathbf{x}\|_2} = 0.} \tag{92}$$

Если же требуется найти минимальную ненулевую ошибку при фиксированном $\|\Delta\mathbf{b}\|_2/\|\mathbf{b}\|_2 = 0{,}01$, то она достигается, когда $\Delta\mathbf{b}$ направлен в сторону, где $\mathbf{A}^{-1}$ имеет минимальное "усиление".

Для нормы $\|\cdot\|_2 = \sum |x_i|$ минимум $\|\mathbf{A}^{-1}\Delta\mathbf{b}\|_2/\|\Delta\mathbf{b}\|_2$ равен $1/\|\mathbf{A}\|_2$ (по свойству согласованных норм).

Следовательно:

$$\min \frac{\|\Delta\mathbf{x}\|_2}{\|\mathbf{x}\|_2} = \frac{1}{\|\mathbf{A}\|_2} \cdot \frac{\|\Delta\mathbf{b}\|_2}{\|\mathbf{b}\|_2} \cdot \frac{\|\mathbf{b}\|_2}{\|\mathbf{x}\|_2} = \frac{1}{232} \cdot 0{,}01 \cdot \frac{190}{3} \approx 0{,}00273. \tag{93}$$

Это значение достигается, когда $\Delta\mathbf{b}$ пропорционален вектору, на котором $\mathbf{A}$ достигает своей нормы.

Итог

- Решение системы: $\mathbf{x} = (2, 1)^T$.
- Максимальная относительная погрешность: $\|\Delta\mathbf{x}\|_2/\|\mathbf{x}\|_2 \leqslant 2{,}4245$ ($\approx 242\%$).
- Оценка достигается на $\Delta\mathbf{b} = \pm(1{,}9, 0)^T$ (с точностью до направления).
- Минимальная относительная ошибка: 0 (при $\Delta\mathbf{b} = \mathbf{0}$).
- Минимальная ненулевая ошибка при заданном $\|\Delta\mathbf{b}\|_2$: $\approx 0{,}00273$ ($\approx 0{,}27\%$).

Задача II.9.14

Условие: Система уравнений $\mathbf{A}\mathbf{x} = \mathbf{f}$, где

$$\mathbf{A} = \begin{pmatrix} 3 & -1 & 1 \\ 2 & 6 & -2 \\ -1 & 1 & 9 \end{pmatrix}, \quad \mathbf{f} = (4, -4, 2)^T,$$

решается с помощью метода простых итераций, начальное приближение нулевое. При каких значениях итерационного параметра метод будет сходиться:

а) при вычислениях с бесконечным числом бит в мантиссе?

б) при длине мантиссы 52 бита?

в) при каком значении итерационного параметра сходимость будет самая быстрая?

г) Найти значение оптимального параметра для первого шага решения системы методом наискорейшего спуска.

Решение:

Предварительный анализ: собственные значения матрицы A

Метод простых итераций с параметром τ имеет вид:

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \tau(\mathbf{A}\mathbf{x}^{(k)} - \mathbf{f}) = (\mathbf{I} - \tau\mathbf{A})\mathbf{x}^{(k)} + \tau\mathbf{f}. \tag{94}$$

Итерационная матрица: $\mathbf{B}(\tau) = \mathbf{I} - \tau\mathbf{A}$.
Метод сходится тогда и только тогда, когда спектральный радиус $\rho(\mathbf{B}(\tau)) < 1$.
Найдём собственные значения матрицы $\mathbf{A}$ из характеристического уравнения $\det(\mathbf{A} - \lambda\mathbf{I}) = 0$:

$$\det \begin{pmatrix} 3-\lambda & -1 & 1 \\ 2 & 6-\lambda & -2 \\ -1 & 1 & 9-\lambda \end{pmatrix} = 0. \tag{95}$$

Раскрывая определитель:

$$\begin{aligned} &(3-\lambda)[(6-\lambda)(9-\lambda)+2] + [2(9-\lambda)-2] + [2+(6-\lambda)] \\ &= (3-\lambda)(\lambda^2 - 15\lambda + 56) + (16 - 2\lambda) + (8-\lambda) \\ &= -\lambda^3 + 18\lambda^2 - 104\lambda + 192 = 0. \end{aligned} \tag{96}$$

Проверяем $\lambda = 4$: $-64 + 288 - 416 + 192 = 0$
Делим на $(\lambda - 4)$: $\lambda^3 - 18\lambda^2 + 104\lambda - 192 = (\lambda - 4)(\lambda^2 - 14\lambda + 48) = 0$.
Корни квадратного уравнения: $\lambda = \frac{14 \pm \sqrt{196-192}}{2} = \frac{14 \pm 2}{2}$, т.е. $\lambda = 8$ и $\lambda = 6$.
Собственные значения матрицы A: $\lambda_1 = 4$, $\lambda_2 = 6$, $\lambda_3 = 8$.
Собственные значения итерационной матрицы $\mathbf{B}(\tau) = \mathbf{I} - \tau\mathbf{A}$:

$$\mu_1 = 1 - 4\tau, \quad \mu_2 = 1 - 6\tau, \quad \mu_3 = 1 - 8\tau. \tag{97}$$

а) Сходимость при бесконечной точности

Метод сходится при $\rho(\mathbf{B}(\tau)) = \max(|\mu_1|, |\mu_2|, |\mu_3|) < 1$:

$$|1 - 4\tau| < 1 \implies 0 < \tau < \frac{1}{2}, \tag{98}$$

$$|1 - 6\tau| < 1 \implies 0 < \tau < \frac{1}{3}, \tag{99}$$

$$|1 - 8\tau| < 1 \implies 0 < \tau < \frac{1}{4}. \tag{100}$$

Пересечение условий:

$$\boxed{0 < \tau < \frac{1}{4}.} \tag{101}$$

б) Сходимость при длине мантиссы 52 бита

При конечной точности вычислений (double precision, $\varepsilon_{\text{маш}} = 2^{-52} \approx 2.22 \cdot 10^{-16}$) метод сходится к окрестности точного решения, если $\rho(\mathbf{B}(\tau)) < 1$. Однако при τ, близком к границам интервала $(0, 1/4)$, спектральный радиус близок к 1, и сходимость становится чрезвычайно медленной.

Практически метод сходится за разумное число итераций, если $\rho(\mathbf{B}(\tau)) < 1 - c\varepsilon_{\text{маш}}$ для некоторой константы c. Это исключает малые окрестности точек $\tau = 0$ и $\tau = 1/4$.

Формально условие сходимости остаётся тем же:

$$\boxed{0 < \tau < \frac{1}{4},} \tag{102}$$

но практически следует выбирать τ подальше от границ, например $\tau \in (10^{-15}, 1/4 - 10^{-15})$.

в) Оптимальный параметр для максимальной скорости сходимости

Нужно минимизировать $\rho(\mathbf{B}(\tau)) = \max(|1 - 4\tau|, |1 - 6\tau|, |1 - 8\tau|)$.

При $\tau \in (0, 1/4)$:

- $1 - 4\tau$ убывает от 1 до 0,

- $1 - 6\tau$ убывает от 1 до $-1/2$,
- $1 - 8\tau$ убывает от 1 до -1.

Максимум по модулю определяется крайними собственными значениями: $\max(|1-4\tau|, |1-8\tau|)$.
Оптимум достигается, когда $|1-4\tau| = |1-8\tau|$:

$$1 - 4\tau = -(1 - 8\tau) \implies 2 = 12\tau \implies \tau_{\text{opt}} = \frac{1}{6}. \tag{103}$$

При $\tau = 1/6$:

$$\mu_1 = 1 - 4 \cdot \frac{1}{6} = \frac{1}{3}, \tag{104}$$

$$\mu_2 = 1 - 6 \cdot \frac{1}{6} = 0, \tag{105}$$

$$\mu_3 = 1 - 8 \cdot \frac{1}{6} = -\frac{1}{3}. \tag{106}$$

$$\boxed{\tau_{\text{opt}} = \frac{1}{6}, \quad \rho(\mathbf{B}(\tau_{\text{opt}})) = \frac{1}{3}.} \tag{107}$$

г) Оптимальный параметр для первого шага метода наискорейшего спуска

При $\mathbf{x}^{(0)} = \mathbf{0}$: невязка $\mathbf{r}^{(0)} = \mathbf{f} - \mathbf{A}\mathbf{x}^{(0)} = \mathbf{f} = (4, -4, 2)^T$.
Метод наискорейшего спуска: $\mathbf{x}^{(1)} = \mathbf{x}^{(0)} + \tau_0 \mathbf{r}^{(0)} = \tau_0 \mathbf{f}$.
Оптимальный τ_0 минимизирует $\|\mathbf{r}^{(1)}\|^2 = \|\mathbf{f} - \mathbf{A}\mathbf{x}^{(1)}\|^2 = \|\mathbf{f} - \tau_0 \mathbf{A}\mathbf{f}\|^2$.
Условие минимума: $\frac{d}{d\tau_0}\|\mathbf{f} - \tau_0 \mathbf{A}\mathbf{f}\|^2 = -2(\mathbf{f} - \tau_0 \mathbf{A}\mathbf{f}, \mathbf{A}\mathbf{f}) = 0$.
Отсюда:

$$\tau_0 = \frac{(\mathbf{f}, \mathbf{A}\mathbf{f})}{(\mathbf{A}\mathbf{f}, \mathbf{A}\mathbf{f})} = \frac{(\mathbf{f}, \mathbf{A}\mathbf{f})}{\|\mathbf{A}\mathbf{f}\|^2}. \tag{108}$$

Вычислим $\mathbf{A}\mathbf{f}$:

$$\mathbf{A}\mathbf{f} = \begin{pmatrix} 3 & -1 & 1 \\ 2 & 6 & -2 \\ -1 & 1 & 9 \end{pmatrix} \begin{pmatrix} 4 \\ -4 \\ 2 \end{pmatrix} = \begin{pmatrix} 12 + 4 + 2 \\ 8 - 24 - 4 \\ -4 - 4 + 18 \end{pmatrix} = \begin{pmatrix} 18 \\ -20 \\ 10 \end{pmatrix}. \tag{109}$$

Скалярное произведение $(\mathbf{f}, \mathbf{A}\mathbf{f})$:

$$(\mathbf{f}, \mathbf{A}\mathbf{f}) = 4 \cdot 18 + (-4) \cdot (-20) + 2 \cdot 10 = 72 + 80 + 20 = 172. \tag{110}$$

Квадрат нормы $\|\mathbf{A}\mathbf{f}\|^2$:

$$\|\mathbf{A}\mathbf{f}\|^2 = 18^2 + (-20)^2 + 10^2 = 324 + 400 + 100 = 824. \tag{111}$$

Оптимальный параметр:

$$\boxed{\tau_0 = \frac{172}{824} = \frac{43}{206} \approx 0.2087.} \tag{112}$$

Итог

- а) Метод сходится при $0 < \tau < 1/4$.
- б) При конечной точности формально условие то же, но практически следует избегать τ близких к 0 и $1/4$.
- в) Оптимальный параметр $\tau_{\text{opt}} = 1/6$, спектральный радиус $\rho = 1/3$.
- г) Для первого шага метода наискорейшего спуска $\tau_0 = 43/206 \approx 0.2087$.

Задача III.4.3

Условие: Предложить алгоритм проведения на плоскости окружности через четыре и более точек методом наименьших квадратов.

Решение:

1. Постановка задачи

Пусть на плоскости заданы N точек с координатами (x_i, y_i), $i = 1, 2, \ldots, N$, причём $N \geqslant 4$. Требуется найти окружность, которая наилучшим образом (в смысле метода наименьших квадратов) аппроксимирует эти точки.

Уравнение окружности с центром в точке (a, b) и радиусом R имеет вид:

$$(x - a)^2 + (y - b)^2 = R^2. \tag{113}$$

Раскроем скобки:

$$x^2 - 2ax + a^2 + y^2 - 2by + b^2 = R^2. \tag{114}$$

Перегруппируем слагаемые, перенеся всё, что зависит от координат точки, в правую часть:

$$2ax + 2by + (R^2 - a^2 - b^2) = x^2 + y^2. \tag{115}$$

Введём обозначение $c = R^2 - a^2 - b^2$. Тогда уравнение окружности принимает вид:

$$2ax + 2by + c = x^2 + y^2. \tag{116}$$

Ключевое наблюдение: уравнение (116) линейно относительно неизвестных параметров a, b и c. Это позволяет свести задачу к решению переопределённой системы линейных алгебраических уравнений (СЛАУ).

2. Составление переопределённой СЛАУ

Подставим координаты каждой из N заданных точек в уравнение (116). Получим систему:

$$\begin{cases} 2ax_1 + 2by_1 + c = x_1^2 + y_1^2, \\ 2ax_2 + 2by_2 + c = x_2^2 + y_2^2, \\ \quad \vdots \\ 2ax_N + 2by_N + c = x_N^2 + y_N^2. \end{cases} \tag{117}$$

В матричной форме эта система записывается как:

$$\mathbf{G}\boldsymbol{\theta} = \mathbf{f}, \tag{118}$$

где

$$\mathbf{G} = \begin{pmatrix} 2x_1 & 2y_1 & 1 \\ 2x_2 & 2y_2 & 1 \\ \vdots & \vdots & \vdots \\ 2x_N & 2y_N & 1 \end{pmatrix}, \quad \boldsymbol{\theta} = \begin{pmatrix} a \\ b \\ c \end{pmatrix}, \quad \mathbf{f} = \begin{pmatrix} x_1^2 + y_1^2 \\ x_2^2 + y_2^2 \\ \vdots \\ x_N^2 + y_N^2 \end{pmatrix}. \tag{119}$$

Поскольку $N \geqslant 4 > 3$, система (118) является переопределённой и, вообще говоря, не имеет точного решения.

3. Метод наименьших квадратов

Вместо точного решения будем искать вектор $\boldsymbol{\theta}$, минимизирующий квадрат евклидовой нормы невязки:

$$\Phi(\boldsymbol{\theta}) = \|\mathbf{G}\boldsymbol{\theta} - \mathbf{f}\|_2^2 = \sum_{i=1}^{N} \bigl(2ax_i + 2by_i + c - (x_i^2 + y_i^2)\bigr)^2 \to \min. \tag{120}$$

Необходимое условие минимума — обращение в нуль градиента Φ по всем компонентам $\boldsymbol{\theta}$:

$$\frac{\partial \Phi}{\partial \boldsymbol{\theta}} = 2\mathbf{G}^T(\mathbf{G}\boldsymbol{\theta} - \mathbf{f}) = \mathbf{0}. \tag{121}$$

Отсюда получаем **нормальную систему** уравнений:

$$\mathbf{G}^T\mathbf{G}\boldsymbol{\theta} = \mathbf{G}^T\mathbf{f}. \tag{122}$$

Матрица $\mathbf{G}^T\mathbf{G}$ имеет размер 3×3. Если точки не лежат на одной прямой, эта матрица невырождена, и решение единственно:

$$\boldsymbol{\theta} = (\mathbf{G}^T\mathbf{G})^{-1}\mathbf{G}^T\mathbf{f}. \tag{123}$$

4. Восстановление радиуса

После того как найдены параметры a, b, c, радиус окружности восстанавливается из соотношения $c = R^2 - a^2 - b^2$:

$$R = \sqrt{a^2 + b^2 + c}. \tag{124}$$

5. Итоговый алгоритм

1. **Входные данные:** координаты N точек (x_i, y_i), $i = 1, \ldots, N$, $N \geqslant 4$.
2. **Шаг 1.** Сформировать матрицу $\mathbf{G}$ размера $N \times 3$ и вектор $\mathbf{f}$ длины N:
$$G_{i1} = 2x_i, \quad G_{i2} = 2y_i, \quad G_{i3} = 1, \quad f_i = x_i^2 + y_i^2. \tag{125}$$
3. **Шаг 2.** Вычислить матрицу $\mathbf{A} = \mathbf{G}^T\mathbf{G}$ размера 3×3 и вектор $\mathbf{b} = \mathbf{G}^T\mathbf{f}$ длины 3.
4. **Шаг 3.** Решить нормальную систему $\mathbf{A}\boldsymbol{\theta} = \mathbf{b}$ относительно $\boldsymbol{\theta} = (a, b, c)^T$.
5. **Шаг 4.** Вычислить радиус: $R = \sqrt{a^2 + b^2 + c}$.
6. **Выходные данные:** центр окружности (a, b) и радиус R.

6. Замечание о численной устойчивости

На практике для повышения численной устойчивости алгоритма рекомендуется перед построением матрицы $\mathbf{G}$ выполнить центрирование данных: вычесть из всех координат x_i и y_i их средние значения $\bar{x}$ и $\bar{y}$. После нахождения параметров в центрированной системе координат центр окружности пересчитывается обратно: $a_{\text{исх}} = a + \bar{x}$, $b_{\text{исх}} = b + \bar{y}$.

Задача III.4.4

Условие: Напряжённость магнитного поля H и магнитная индукция B связаны соотношением $B = H/(a + bH)$. По результатам экспериментальных измерений определить коэффициенты a и b:

H	8	10	15	20	30	40	60	80
B	13,0	14,0	15,4	16,3	17,2	17,8	18,5	18,8

Решение:

1. Теоретическое обоснование метода итерированного веса

Исходная задача состоит в минимизации нелинейного функционала невязки:

$$\Phi(a, b) = \sum_{i=1}^{N} \left(B_i - \frac{H_i}{a + bH_i} \right)^2 \to \min . \tag{126}$$

Прямая минимизация (126) приводит к системе нелинейных уравнений. Чтобы свести задачу к линейной, выполним алгебраическое преобразование *внутри* квадрата невязки. Приведём выражение в скобках к общему знаменателю:

$$B_i - \frac{H_i}{a + bH_i} = \frac{aB_i + bB_iH_i - H_i}{a + bH_i}. \tag{127}$$

Подставим это обратно в функционал (126):

$$\Phi(a, b) = \sum_{i=1}^{N} \frac{(aB_i + bB_iH_i - H_i)^2}{(a + bH_i)^2} = \sum_{i=1}^{N} w_i(a, b) \cdot (aB_i + bB_iH_i - H_i)^2 \to \min, \tag{128}$$

где введены **веса**:

$$w_i(a, b) = \frac{1}{(a + bH_i)^2}. \tag{129}$$

Формула (128) представляет собой задачу **взвешенного метода наименьших квадратов (ВМНК)** для линейного уравнения $aB_i + bB_iH_i = H_i$. Однако веса w_i зависят от искомых параметров a и b, поэтому мы не можем решить эту систему за один шаг. Для этого применяется **метод итерированного веса** (Iteratively Reweighted Least Squares, IRLS).

2. Алгоритм метода итерированного веса

1. **Нулевая итерация (начальное приближение):** Решаем задачу *невзвешенного* МНК (полагая $w_i^{(0)} = 1$), чтобы получить начальные оценки a_0 и b_0.
2. **k-я итерация:**
   (a) Вычисляем веса на основе предыдущих оценок: $w_i^{(k)} = \frac{1}{(a_{k-1} + b_{k-1}H_i)^2}$.
   (b) Решаем взвешенную нормальную систему:

$$\begin{cases} a \sum w_i^{(k)} B_i^2 + b \sum w_i^{(k)} B_i^2 H_i = \sum w_i^{(k)} B_i H_i, \\ a \sum w_i^{(k)} B_i^2 H_i + b \sum w_i^{(k)} B_i^2 H_i^2 = \sum w_i^{(k)} B_i H_i^2. \end{cases} \tag{130}$$

   (c) Получаем новые оценки a_k и b_k.
3. **Критерий остановки:** Повторяем шаг 2 до тех пор, пока изменения параметров $|a_k - a_{k-1}|$ и $|b_k - b_{k-1}|$ не станут меньше заданной точности (например, 10^{-4}).

3. Численная реализация

Шаг 0. Невзвешенное начальное приближение. Решая систему с $w_i = 1$ (как в классическом линейном МНК), получаем:

$$a_0 \approx 0{,}218, \quad b_0 \approx 0{,}0506. \tag{131}$$

Шаг 1. Первая итерация с весами. Вычислим веса $w_i^{(1)} = \frac{1}{(0{,}218 + 0{,}0506 \cdot H_i)^2}$ для каждой точки:

H_i	$a_0 + b_0 H_i$	$w_i^{(1)}$	$w_i^{(1)} B_i^2$
8	0,623	2,57	434,3
10	0,724	1,91	374,4
15	0,977	1,05	248,9
20	1,230	0,66	174,9
30	1,736	0,33	97,4
40	2,242	0,20	63,2
60	3,254	0,09	30,8
80	4,266	0,05	17,7

Подставляя эти веса в нормальную систему, вычисляем суммы:

$$\sum w_i B_i^2 \approx 1441,6, \qquad \sum w_i B_i^2 H_i \approx 23177,$$
$$\sum w_i B_i^2 H_i^2 \approx 606100, \qquad \sum w_i B_i H_i \approx 1477,$$
$$\sum w_i B_i H_i^2 \approx 35456.$$

Решаем систему:

$$\begin{pmatrix} 1441{,}6 & 23177 \\ 23177 & 606100 \end{pmatrix} \begin{pmatrix} a_1 \\ b_1 \end{pmatrix} = \begin{pmatrix} 1477 \\ 35456 \end{pmatrix}. \tag{132}$$

Определитель системы $\Delta \approx 3{,}36 \cdot 10^8$. Находим:

$$a_1 = \frac{1477 \cdot 606100 - 23177 \cdot 35456}{\Delta} \approx 0{,}218, \quad b_1 = \frac{1441{,}6 \cdot 35456 - 1477 \cdot 23177}{\Delta} \approx 0{,}0501. \tag{133}$$

Шаг 2 и далее. Повторение процедуры с новыми весами $w_i^{(2)} = \frac{1}{(0{,}218+0{,}0501 \cdot H_i)^2}$ показывает, что значения a и b практически перестают меняться (изменения меньше 10^{-4}). Метод сошёлся.

4. Итоговые результаты и проверка

Оптимальные значения коэффициентов:

$$\boxed{a \approx 0{,}218, \quad b \approx 0{,}0501.} \tag{134}$$

Уравнение кривой намагничивания:

$$B = \frac{H}{0{,}218 + 0{,}0501 H}. \tag{135}$$

Проверим качество аппроксимации, вычислив невязки $\Delta B_i = B_{i,\text{изм}} - B_{i,\text{расч}}$:

H	$B_{\text{изм}}$	$B_{\text{расч}}$	Невязка ΔB
8	13,0	12,93	+0,07
10	14,0	13,88	+0,12
15	15,4	15,38	+0,02
20	16,3	16,30	0,00
30	17,2	17,31	-0,11
40	17,8	17,86	-0,06
60	18,5	18,46	+0,04
80	18,8	18,77	+0,03

Сумма невязок близка к нулю ($\sum \Delta B_i \approx 0{,}11$), а максимальное отклонение не превышает 0,12 (менее 1% от максимального значения B).

5. Физическая интерпретация

- Параметр $a \approx 0{,}218$ определяет начальную магнитную проницаемость: $\mu_0 \approx 1/a \approx 4{,}6$.
- Параметр $b \approx 0{,}0501$ определяет уровень магнитного насыщения: $B_{\text{нас}} = 1/b \approx 19{,}96$ Тл, что полностью согласуется с поведением ферромагнетиков при больших H.

Задача III.4.8

Условие: Пусть замеры функции $y = f(x)$ осуществлены в точках $x_k = \cos\frac{\pi(1+2k)}{2(n+1)}$, $k = 0, 1, \ldots, n$, являющихся нулями многочлена Чебышёва $T_{n+1}(x)$, и собраны в таблицу. Среди многочленов степени не выше заданного k, $0 \le k \le n$, указать тот многочлен $P_k(x)$, который наилучшим (в смысле метода наименьших квадратов) образом приближает заданную функцию.

Провести вычисления в случае $n = 3$:

x	x_0	x_1	x_2	x_3
y	2	1	3	0

Решение:

1. Теоретическая часть

Ищем приближающий многочлен в виде разложения по многочленам Чебышёва:

$$P_k(x) = \sum_{j=0}^{k} C_j T_j(x), \quad 0 \le k \le n. \tag{136}$$

Функционал метода наименьших квадратов имеет вид:

$$\Phi(C_0, C_1, \ldots, C_k) = \sum_{m=0}^{n} \left(y_m - \sum_{j=0}^{k} C_j T_j(x_m) \right)^2 \to \min. \tag{137}$$

Ключевое свойство, на которое указывает условие задачи: многочлены Чебышёва $T_j(x)$ образуют **ортогональную систему** на множестве нулей $T_{n+1}(x)$ с единичными весами. А именно, для $x_m = \cos\frac{\pi(1+2m)}{2(n+1)}$ выполняется:

$$\sum_{m=0}^{n} T_i(x_m) T_j(x_m) = \begin{cases} 0, & i \ne j, \\ n+1, & i = j = 0, \\ \frac{n+1}{2}, & i = j \ne 0. \end{cases} \tag{138}$$

Благодаря ортогональности (138) нормальная система МНК **диагонализируется**, и каждый коэффициент C_j находится независимо из условия $\frac{\partial \Phi}{\partial C_j} = 0$:

$$C_j = \frac{\sum\limits_{m=0}^{n} y_m T_j(x_m)}{\sum\limits_{m=0}^{n} T_j^2(x_m)}. \tag{139}$$

Подставляя значения норм из (138), получаем явные формулы:

$$C_0 = \frac{1}{n+1} \sum_{m=0}^{n} y_m, \qquad C_j = \frac{2}{n+1} \sum_{m=0}^{n} y_m T_j(x_m), \quad j = 1, 2, \ldots, k. \tag{140}$$

2. Вычисления для $n = 3$

Узлы интерполяции — нули многочлена $T_4(x)$:

$$x_m = \cos\frac{\pi(1+2m)}{8}, \quad m = 0, 1, 2, 3. \tag{141}$$

Выпишем их явно:

$$x_0 = \cos\frac{\pi}{8} = \frac{\sqrt{2+\sqrt{2}}}{2} \approx 0{,}92388, \tag{142}$$

$$x_1 = \cos\frac{3\pi}{8} = \frac{\sqrt{2-\sqrt{2}}}{2} \approx 0{,}38268, \tag{143}$$

$$x_2 = \cos\frac{5\pi}{8} = -\frac{\sqrt{2-\sqrt{2}}}{2} \approx -0{,}38268, \tag{144}$$

$$x_3 = \cos\frac{7\pi}{8} = -\frac{\sqrt{2+\sqrt{2}}}{2} \approx -0{,}92388. \tag{145}$$

Значения многочленов Чебышёва $T_j(x_m) = \cos\frac{j\pi(1+2m)}{8}$ в узлах:

	$m=0$	$m=1$	$m=2$	$m=3$
$T_0(x_m)$	1	1	1	1
$T_1(x_m)$	$\cos\frac{\pi}{8}$	$\cos\frac{3\pi}{8}$	$-\cos\frac{3\pi}{8}$	$-\cos\frac{\pi}{8}$
$T_2(x_m)$	$\cos\frac{\pi}{4}=\frac{\sqrt{2}}{2}$	$\cos\frac{3\pi}{4}=-\frac{\sqrt{2}}{2}$	$\cos\frac{5\pi}{4}=-\frac{\sqrt{2}}{2}$	$\cos\frac{7\pi}{4}=\frac{\sqrt{2}}{2}$
$T_3(x_m)$	$\cos\frac{3\pi}{8}$	$-\cos\frac{\pi}{8}$	$\cos\frac{\pi}{8}$	$-\cos\frac{3\pi}{8}$

Коэффициент C_0:

$$C_0 = \frac{1}{4}(y_0+y_1+y_2+y_3) = \frac{1}{4}(2+1+3+0) = \frac{3}{2}. \tag{146}$$

Коэффициент C_1:

$$\begin{aligned} C_1 &= \frac{2}{4}\sum_{m=0}^{3} y_m T_1(x_m) = \frac{1}{2}\left(2\cos\frac{\pi}{8} + 1\cdot\cos\frac{3\pi}{8} + 3\cdot\left(-\cos\frac{3\pi}{8}\right) + 0\cdot\left(-\cos\frac{\pi}{8}\right)\right) \\ &= \frac{1}{2}\left(2\cos\frac{\pi}{8} - 2\cos\frac{3\pi}{8}\right) = \cos\frac{\pi}{8} - \cos\frac{3\pi}{8} = \frac{\sqrt{2+\sqrt{2}}-\sqrt{2-\sqrt{2}}}{2} \approx 0{,}5412. \end{aligned} \tag{147}$$

Коэффициент C_2:

$$\begin{aligned} C_2 &= \frac{2}{4}\sum_{m=0}^{3} y_m T_2(x_m) = \frac{1}{2}\left(2\cdot\frac{\sqrt{2}}{2} + 1\cdot\left(-\frac{\sqrt{2}}{2}\right) + 3\cdot\left(-\frac{\sqrt{2}}{2}\right) + 0\cdot\frac{\sqrt{2}}{2}\right) \\ &= \frac{1}{2}\left(\sqrt{2} - \frac{\sqrt{2}}{2} - \frac{3\sqrt{2}}{2}\right) = \frac{1}{2}\left(-\sqrt{2}\right) = -\frac{\sqrt{2}}{2} \approx -0{,}7071. \end{aligned} \tag{148}$$

Коэффициент C_3:

$$\begin{aligned} C_3 &= \frac{2}{4}\sum_{m=0}^{3} y_m T_3(x_m) = \frac{1}{2}\left(2\cos\frac{3\pi}{8} + 1\cdot\left(-\cos\frac{\pi}{8}\right) + 3\cdot\cos\frac{\pi}{8} + 0\cdot\left(-\cos\frac{3\pi}{8}\right)\right) \\ &= \frac{1}{2}\left(2\cos\frac{3\pi}{8} + 2\cos\frac{\pi}{8}\right) = \cos\frac{\pi}{8} + \cos\frac{3\pi}{8} = \frac{\sqrt{2+\sqrt{2}}+\sqrt{2-\sqrt{2}}}{2} \approx 1{,}3066. \end{aligned} \tag{149}$$

3. Искомые многочлены наилучшего приближения

Подставляя найденные коэффициенты в формулу (136), получаем:

$$P_0(x) = \frac{3}{2}, \tag{150}$$

$$P_1(x) = \frac{3}{2} + \left(\cos\frac{\pi}{8} - \cos\frac{3\pi}{8}\right)T_1(x) = \frac{3}{2} + \left(\cos\frac{\pi}{8} - \cos\frac{3\pi}{8}\right)x, \tag{151}$$

$$P_2(x) = P_1(x) - \frac{\sqrt{2}}{2}\,T_2(x) = \frac{3}{2} + \left(\cos\frac{\pi}{8} - \cos\frac{3\pi}{8}\right)x - \frac{\sqrt{2}}{2}(2x^2-1), \tag{152}$$

$$\begin{aligned} P_3(x) &= P_2(x) + \left(\cos\frac{\pi}{8} + \cos\frac{3\pi}{8}\right)T_3(x) \\ &= \frac{3}{2} + \left(\cos\frac{\pi}{8} - \cos\frac{3\pi}{8}\right)x - \frac{\sqrt{2}}{2}(2x^2-1) + \left(\cos\frac{\pi}{8} + \cos\frac{3\pi}{8}\right)(4x^3-3x). \end{aligned} \tag{153}$$

Замечание. Поскольку при $n=3$ многочлен $P_3(x)$ имеет степень 3 и строится по 4 узлам, он совпадает с интерполяционным многочленом Лагранжа и точно проходит через все заданные точки. Многочлены P_0, P_1, P_2 дают наилучшее среднеквадратичное приближение среди всех многочленов соответствующей степени.

4. Численная проверка

Для контроля вычислим значения $P_3(x_m)$ и убедимся, что они совпадают с табличными y_m. Например, для $m = 0$:

$$
\begin{aligned}
P_3(x_0) &= C_0 + C_1 T_1(x_0) + C_2 T_2(x_0) + C_3 T_3(x_0) \\
&= \frac{3}{2} + \left(\cos\frac{\pi}{8} - \cos\frac{3\pi}{8}\right)\cos\frac{\pi}{8} - \frac{\sqrt{2}}{2}\cdot\frac{\sqrt{2}}{2} + \left(\cos\frac{\pi}{8} + \cos\frac{3\pi}{8}\right)\cos\frac{3\pi}{8} \\
&= \frac{3}{2} + \cos^2\frac{\pi}{8} - \cos\frac{\pi}{8}\cos\frac{3\pi}{8} - \frac{1}{2} + \cos\frac{\pi}{8}\cos\frac{3\pi}{8} + \cos^2\frac{3\pi}{8} \\
&= 1 + \cos^2\frac{\pi}{8} + \cos^2\frac{3\pi}{8} = 1 + \frac{1+\cos\frac{\pi}{4}}{2} + \frac{1+\cos\frac{3\pi}{4}}{2} = 1 + \frac{1}{2} + \frac{1}{2} = 2 = y_0. \quad \checkmark
\end{aligned}
\tag{154}
$$

Аналогично проверяются остальные узлы.