Задача I.6.6

Условие: Пусть функция $f(x)$ задана таблично: заданы значения аргументов $x_0 < x_1 < x_2 < \ldots < x_N$ (расстояние между двумя соседними точками h) и значения функции в них $f_0, f_1, \ldots, f_N$.

Самостоятельно выведите формулу вычисления *односторонней* производной для приближенного вычисления $f'(x)$ в точках x_0 и x_N с точностью до $O(h^2)$ и $O(h^3)$. Найдите оптимальные шаги численного дифференцирования. Сравните их с оценками для центральных разностей.

Решение:

1. Формула односторонней разности второго порядка $O(h^2)$

Ищем приближение для $f'(x_0)$ в виде:

$$f'(x_0) \approx \frac{a_0 f(x_0) + a_1 f(x_1) + a_2 f(x_2)}{h}. \tag{1}$$

Разложим $f(x_1)$ и $f(x_2)$ в ряд Тейлора в точке x_0:

$$f(x_1) = f(x_0) + hf'(x_0) + \frac{h^2}{2} f''(x_0) + \frac{h^3}{6} f'''(x_0) + O(h^4), \tag{2}$$

$$f(x_2) = f(x_0) + 2hf'(x_0) + 2h^2 f''(x_0) + \frac{4h^3}{3} f'''(x_0) + O(h^4). \tag{3}$$

Подставим в (1) и сгруппируем по степеням h:

$$\begin{aligned}\frac{a_0 f(x_0) + a_1 f(x_1) + a_2 f(x_2)}{h} = {} & \frac{a_0 + a_1 + a_2}{h} f(x_0) + (a_1 + 2a_2) f'(x_0) \\ & + \frac{h}{2}(a_1 + 4a_2) f''(x_0) + \frac{h^2}{6}(a_1 + 8a_2) f'''(x_0) + O(h^3).\end{aligned} \tag{4}$$

Чтобы это выражение приближало $f'(x_0)$ с точностью $O(h^2)$, приравниваем:

$$\begin{cases} a_0 + a_1 + a_2 = 0, \\ a_1 + 2a_2 = 1, \\ a_1 + 4a_2 = 0. \end{cases} \tag{5}$$

Решаем: из третьего $a_1 = -4a_2$; подставляем во второе: $-2a_2 = 1 \Rightarrow a_2 = -\frac{1}{2}$, $a_1 = 2$, $a_0 = -\frac{3}{2}$.

$$\boxed{f'(x_0) \approx \frac{-3f(x_0) + 4f(x_1) - f(x_2)}{2h}.} \tag{6}$$

Погрешность метода:

$$E_{\text{мет}} = \frac{h^2}{6}(a_1 + 8a_2) f'''(x_0) = \frac{h^2}{6}(2 - 4) f'''(x_0) = -\frac{h^2}{3} f'''(x_0). \tag{7}$$

2. Формула для точки x_N

Аналогично, для точки x_N используем значения $f(x_N)$, $f(x_{N-1})$, $f(x_{N-2})$:

$$f'(x_N) \approx \frac{b_0 f(x_N) + b_1 f(x_{N-1}) + b_2 f(x_{N-2})}{h}. \tag{8}$$

Подставляя разложения Тейлора и приравнивая коэффициенты, получаем систему:

$$\begin{cases} b_0 + b_1 + b_2 = 0, \\ -(b_1 + 2b_2) = 1, \\ b_1 + 4b_2 = 0. \end{cases} \tag{9}$$

Решение: $b_2 = \frac{1}{2}$, $b_1 = -2$, $b_0 = \frac{3}{2}$.

$$\boxed{f'(x_N) \approx \frac{3f(x_N) - 4f(x_{N-1}) + f(x_{N-2})}{2h}.} \tag{10}$$

3. Формула третьего порядка $O(h^3)$

Для получения точности $O(h^3)$ нужно обнулить коэффициент при $f'''(x_0)$, что требует четырёх неизвестных. Ищем:

$$f'(x_0) \approx \frac{c_0 f(x_0) + c_1 f(x_1) + c_2 f(x_2) + c_3 f(x_3)}{h}. \tag{11}$$

Разложения:

$$f(x_1) = f + hf' + \tfrac{h^2}{2} f'' + \tfrac{h^3}{6} f''' + \tfrac{h^4}{24} f^{(4)} + O(h^5), \tag{12}$$

$$f(x_2) = f + 2hf' + 2h^2 f'' + \tfrac{4h^3}{3} f''' + \tfrac{2h^4}{3} f^{(4)} + O(h^5), \tag{13}$$

$$f(x_3) = f + 3hf' + \tfrac{9h^2}{2} f'' + \tfrac{9h^3}{2} f''' + \tfrac{27h^4}{8} f^{(4)} + O(h^5). \tag{14}$$

Условия для точности $O(h^3)$:

$$\begin{cases} c_0 + c_1 + c_2 + c_3 = 0, \\ c_1 + 2c_2 + 3c_3 = 1, \\ c_1 + 4c_2 + 9c_3 = 0, \\ c_1 + 8c_2 + 27c_3 = 0. \end{cases} \tag{15}$$

Решаем: из третьего и четвёртого $4c_2 + 18c_3 = 0 \Rightarrow c_2 = -\frac{9}{2} c_3$; из второго и третьего $2c_2 + 6c_3 = -1 \Rightarrow -3c_3 = -1 \Rightarrow c_3 = \frac{1}{3}$, $c_2 = -\frac{3}{2}$, $c_1 = 3$, $c_0 = -\frac{11}{6}$.

$$\boxed{f'(x_0) \approx \frac{-11 f(x_0) + 18 f(x_1) - 9 f(x_2) + 2 f(x_3)}{6h}}. \tag{16}$$

Погрешность:

$$E_{\text{мет}} = \frac{h^3}{24}(c_1 + 16c_2 + 81c_3) f^{(4)}(x_0) = \frac{h^3}{24}(3 - 24 + 27) f^{(4)}(x_0) = \frac{h^3}{4} f^{(4)}(x_0). \tag{17}$$

Ответ на вопрос задачи: Для получения формулы третьего порядка аппроксимации нужно взять **четыре члена** (значения функции в четырёх точках).

4. Оптимальный шаг дифференцирования

Полная погрешность численного дифференцирования складывается из погрешности метода и погрешности вычислений (ошибок округления). Если каждое значение функции вычислено с абсолютной погрешностью ε, то округлительная погрешность формулы равна

$$E_{\text{окр}} = \frac{\sum |c_i|}{h}\, \varepsilon,$$

где c_i — коэффициенты в числителе формулы.

Для формулы второго порядка (6)**:** Коэффициенты в числителе: $-\frac{3}{2}$, 2, $-\frac{1}{2}$. Сумма модулей:

$$\left|-\tfrac{3}{2}\right| + |2| + \left|-\tfrac{1}{2}\right| = \tfrac{3}{2} + 2 + \tfrac{1}{2} = 4.$$

Полная погрешность:

$$E_{\text{полн}} \approx \frac{h^2}{3} |f'''(x_0)| + \frac{4\varepsilon}{h}. \tag{18}$$

Минимизируем по h:

$$\frac{dE_{\text{полн}}}{dh} = \frac{2h}{3} |f'''(x_0)| - \frac{4\varepsilon}{h^2} = 0 \implies h^3 = \frac{6\varepsilon}{|f'''(x_0)|}. \tag{19}$$

$$\boxed{h^{(2)}_{\text{opt}} = \left(\frac{6\varepsilon}{|f'''(x_0)|}\right)^{1/3} \sim \varepsilon^{1/3}}. \tag{20}$$

Для формулы третьего порядка (16)**:** Коэффициенты в числителе: $-\frac{11}{6}$, 3, $-\frac{3}{2}$, $\frac{1}{3}$. Сумма модулей:

$$\tfrac{11}{6} + 3 + \tfrac{3}{2} + \tfrac{1}{3} = \frac{11 + 18 + 9 + 2}{6} = \frac{40}{6} = \frac{20}{3}.$$

Полная погрешность:

$$E_{\text{полн}} \approx \frac{h^3}{4} |f^{(4)}(x_0)| + \frac{20\varepsilon}{3h}. \tag{21}$$

Минимизируем:

$$\frac{dE_{\text{полн}}}{dh} = \frac{3h^2}{4}|f^{(4)}(x_0)| - \frac{20\varepsilon}{3h^2} = 0 \implies h^4 = \frac{80\varepsilon}{9|f^{(4)}(x_0)|}. \tag{22}$$

$$\boxed{h_{\text{opt}}^{(3)} = \left(\frac{80\varepsilon}{9|f^{(4)}(x_0)|}\right)^{1/4} \sim \varepsilon^{1/4}.} \tag{23}$$

5. Сравнение с центральными разностями

Центральная разность второго порядка:

$$f'(x) \approx \frac{f(x+h) - f(x-h)}{2h}, \quad E_{\text{мет}} = \frac{h^2}{6}|f'''(x)|. \tag{24}$$

Сумма модулей коэффициентов в числителе: $1 + 1 = 2$, делённая на 2 — получаем 1. Округлительная погрешность: ε/h.

$$E_{\text{полн}} \approx \frac{h^2}{6}|f'''| + \frac{\varepsilon}{h} \implies h_{\text{opt}}^{\text{centr},2} = \left(\frac{3\varepsilon}{|f'''(x)|}\right)^{1/3} \sim \varepsilon^{1/3}. \tag{25}$$

Центральная разность четвёртого порядка:

$$f'(x) \approx \frac{-f(x+2h) + 8f(x+h) - 8f(x-h) + f(x-2h)}{12h}, \quad E_{\text{мет}} = \frac{h^4}{30}|f^{(5)}(x)|. \tag{26}$$

Сумма модулей коэффициентов в числителе: $1 + 8 + 8 + 1 = 18$, делённая на 12 — получаем $\frac{3}{2}$. Округлительная погрешность: $\frac{3\varepsilon}{2h}$.

$$E_{\text{полн}} \approx \frac{h^4}{30}|f^{(5)}| + \frac{3\varepsilon}{2h} \implies h_{\text{opt}}^{\text{centr},4} = \left(\frac{45\varepsilon}{4|f^{(5)}(x)|}\right)^{1/5} \sim \varepsilon^{1/5}. \tag{27}$$

Сравнение:

- Односторонние и центральные разности одного и того же порядка аппроксимации имеют одинаковую зависимость оптимального шага от ε: $\varepsilon^{1/3}$ для второго порядка, $\varepsilon^{1/4}$ для третьего и $\varepsilon^{1/5}$ для четвёртого.
- Однако односторонние разности требуют *большего числа точек* для достижения того же порядка: для $O(h^2)$ — 3 точки (против 2 у центральной), для $O(h^3)$ — 4 точки (а центральная при 4 точках даёт уже $O(h^4)$).
- Центральные разности всегда предпочтительнее во внутренних узлах сетки, когда есть возможность использовать точки с обеих сторон. Односторонние формулы необходимы только на границах.

Итог

- Формула односторонней разности второго порядка: $f'(x_0) \approx \dfrac{-3f(x_0) + 4f(x_1) - f(x_2)}{2h}$.
- Формула односторонней разности третьего порядка: $f'(x_0) \approx \dfrac{-11f(x_0) + 18f(x_1) - 9f(x_2) + 2f(x_3)}{6h}$.
- Для третьего порядка нужно 4 члена.
- Оптимальный шаг для второго порядка: $h_{\text{opt}} \sim \varepsilon^{1/3}$, точная формула $h_{\text{opt}}^{(2)} = \left(\dfrac{6\varepsilon}{|f'''|}\right)^{1/3}$.
- Оптимальный шаг для третьего порядка: $h_{\text{opt}} \sim \varepsilon^{1/4}$, точная формула $h_{\text{opt}}^{(3)} = \left(\dfrac{80\varepsilon}{9|f^{(4)}|}\right)^{1/4}$.
- Центральные разности эффективнее односторонних при том же порядке точности.

Задача I.8.9

Условие: Найти абсолютную предельную погрешность для функции $u = \sin t$, если заданы точка приближения $t^* = \pi/4$, значение функции u^* в этой точке и погрешность $\Delta t^* = 0{,}05$.

Решение:

1. Исходные данные

Задана функция:

$$u(t) = \sin t. \tag{28}$$

Приближённое значение аргумента:

$$t^* = \frac{\pi}{4} \approx 0{,}7854. \tag{29}$$

Абсолютная погрешность аргумента:

$$\Delta t^* = 0{,}05. \tag{30}$$

Значение функции в точке приближения:

$$u^* = u(t^*) = \sin\frac{\pi}{4} = \frac{\sqrt{2}}{2} \approx 0{,}7071. \tag{31}$$

2. Формула линейной оценки погрешности

Если функция $u(t)$ дифференцируема в окрестности точки t^*, то абсолютная погрешность функции Δu^* оценивается по формуле:

$$\Delta u^* \approx \left|\frac{du}{dt}\Big|_{t=t^*}\right| \cdot \Delta t^*. \tag{32}$$

Эта формула следует из разложения функции в ряд Тейлора в окрестности точки t^* с отбрасыванием членов второго и высших порядков малости (линеаризация).

3. Вычисление производной

Найдём производную функции $u(t) = \sin t$:

$$\frac{du}{dt} = \cos t. \tag{33}$$

Вычислим значение производной в точке $t^* = \pi/4$:

$$\frac{du}{dt}\Big|_{t=\pi/4} = \cos\frac{\pi}{4} = \frac{\sqrt{2}}{2} \approx 0{,}7071. \tag{34}$$

4. Линейная оценка абсолютной погрешности

Подставим найденные значения в формулу (32):

$$\Delta u^* \approx \left|\frac{\sqrt{2}}{2}\right| \cdot 0{,}05 = \frac{\sqrt{2}}{2} \cdot 0{,}05 \approx 0{,}0354. \tag{35}$$

Таким образом, абсолютная предельная погрешность функции $u = \sin t$ при $t^* = \pi/4$ и $\Delta t^* = 0{,}05$ равна:

$$\boxed{\Delta u^* \approx 0{,}0354.} \tag{36}$$

5. Относительная погрешность

Относительная погрешность функции определяется как:

$$\delta u^* = \frac{\Delta u^*}{|u^*|} = \frac{0{,}0354}{0{,}7071} \approx 0{,}05. \tag{37}$$

Таким образом, относительная погрешность составляет примерно 5%, что совпадает с относительной погрешностью аргумента $\delta t^* = \Delta t^*/|t^*| = 0{,}05/(\pi/4) \approx 0{,}0637$ (6,37%).

Интересное наблюдение: Относительная погрешность функции (5%) меньше относительной погрешности аргумента (6,37%). Это связано с тем, что в точке $t^* = \pi/4$ производная $\cos(\pi/4) \approx 0{,}7071 < 1$, то есть функция растёт медленнее, чем аргумент. Коэффициент усиления погрешности равен $|u'(t^*)| = \cos(\pi/4) \approx 0{,}7071$, что меньше единицы.

6. Проверка результата

Для контроля вычислим точные значения функции на границах интервала неопределённости аргумента $t \in [t^* - \Delta t^*, t^* + \Delta t^*] = [\pi/4 - 0{,}05; \pi/4 + 0{,}05] \approx [0{,}7354; 0{,}8354]$:

$$u(\pi/4 - 0{,}05) = \sin(0{,}7354) \approx 0{,}6707, \tag{38}$$

$$u(\pi/4 + 0{,}05) = \sin(0{,}8354) \approx 0{,}7415. \tag{39}$$

Максимальное отклонение от $u^* = \sqrt{2}/2 \approx 0{,}7071$:

$$\max\big(|u(\pi/4 - 0{,}05) - u^*|, |u(\pi/4 + 0{,}05) - u^*|\big) = \max(0{,}0364; 0{,}0344) \approx 0{,}0364. \tag{40}$$

Линейная оценка $\Delta u^* \approx 0{,}0354$ близка к точному значению 0,0364, что подтверждает корректность применения формулы (32). Небольшое расхождение ($\approx 3\%$) объясняется отброшенными членами высшего порядка малости в разложении Тейлора.

7. Анализ асимметрии погрешности

Обратим внимание, что точное максимальное отклонение 0,0364 достигается при $t = \pi/4 - 0{,}05$ (движение влево), а не при $t = \pi/4 + 0{,}05$ (движение вправо), где отклонение составляет 0,0344. Эта асимметрия объясняется вогнутостью функции $\sin t$ в точке $t^* = \pi/4$:

$$u''(t) = -\sin t, \quad u''(\pi/4) = -\frac{\sqrt{2}}{2} < 0. \tag{41}$$

Поскольку вторая производная отрицательна, функция выпукла вверх, и касательная лежит выше графика функции. При движении вправо от t^* реальное значение функции растёт медленнее, чем предсказывает линейная оценка, а при движении влево — убывает быстрее.

8. Квадратичная поправка

Для повышения точности можно добавить член с второй производной:

$$\Delta u^* \approx |u'(t^*)| \cdot \Delta t^* + \frac{1}{2}|u''(t^*)| \cdot (\Delta t^*)^2 = \frac{\sqrt{2}}{2} \cdot 0{,}05 + \frac{1}{2} \cdot \frac{\sqrt{2}}{2} \cdot 0{,}0025 \approx 0{,}0354 + 0{,}0009 = 0{,}0363, \tag{42}$$

что практически совпадает с точным значением 0,0364.

Итог

- Абсолютная предельная погрешность: $\Delta u^* \approx 0{,}0354$.
- Относительная погрешность: $\delta u^* \approx 5\%$.
- Коэффициент усиления погрешности: $|u'(t^*)| = \cos(\pi/4) \approx 0{,}7071 < 1$ (погрешность ослабляется).
- Точное максимальное отклонение: $\approx 0{,}0364$ (расхождение с линейной оценкой $\approx 3\%$).

Задача I.8.30

Условие: Табличная функция $\{f_n\}$ есть проекция на равномерную сетку с шагом h функции $f(x)$. Известно, что $|f'''(x)| \le 1$. Построить формулу для приближенного вычисления $f'(x_0)$ со вторым порядком аппроксимации. Оценить погрешность метода. Найти оптимальный шаг численного дифференцирования.

Решение:

1. Построение формулы численного дифференцирования

Для приближенного вычисления первой производной $f'(x_0)$ со вторым порядком аппроксимации используем формулу центральной разности:

$$f'(x_0) \approx \frac{f(x_0 + h) - f(x_0 - h)}{2h}. \tag{43}$$

Обоснование выбора формулы: Формула центральной разности использует значения функции в двух соседних узлах сетки $x_0 + h$ и $x_0 - h$, симметричных относительно точки x_0. Это обеспечивает второй порядок аппроксимации $O(h^2)$, что соответствует требованию задачи.

2. Оценка погрешности метода

Разложим $f(x_0 + h)$ и $f(x_0 - h)$ в ряд Тейлора в точке x_0:

$$f(x_0 + h) = f(x_0) + hf'(x_0) + \frac{h^2}{2}f''(x_0) + \frac{h^3}{6}f'''(\xi_1), \quad \xi_1 \in (x_0, x_0 + h), \tag{44}$$

$$f(x_0 - h) = f(x_0) - hf'(x_0) + \frac{h^2}{2}f''(x_0) - \frac{h^3}{6}f'''(\xi_2), \quad \xi_2 \in (x_0 - h, x_0). \tag{45}$$

Вычтем второе равенство из первого:

$$f(x_0 + h) - f(x_0 - h) = 2hf'(x_0) + \frac{h^3}{6}\big(f'''(\xi_1) + f'''(\xi_2)\big). \tag{46}$$

Разделим на $2h$:

$$\frac{f(x_0 + h) - f(x_0 - h)}{2h} = f'(x_0) + \frac{h^2}{12}\big(f'''(\xi_1) + f'''(\xi_2)\big). \tag{47}$$

Погрешность метода (ошибка усечения):

$$E_{\text{мет}} = \frac{h^2}{12}\big(f'''(\xi_1) + f'''(\xi_2)\big). \tag{48}$$

Используя условие $|f'''(x)| \le 1$, получаем оценку:

$$|E_{\text{мет}}| \le \frac{h^2}{12} \cdot 2 = \frac{h^2}{6}. \tag{49}$$

Таким образом, формула (43) имеет второй порядок аппроксимации: $E_{\text{мет}} = O(h^2)$.

3. Учет погрешности вычислений

При численной реализации значения функции $f(x_0 \pm h)$ вычисляются с погрешностью округления ε (машинная точность). Обозначим вычисленные значения как $\tilde{f}(x_0 \pm h) = f(x_0 \pm h) + \delta_{\pm}$, где $|\delta_{\pm}| \le \varepsilon$.

Тогда вычисленное значение производной:

$$\tilde{f}'(x_0) = \frac{\tilde{f}(x_0 + h) - \tilde{f}(x_0 - h)}{2h} = \frac{f(x_0 + h) - f(x_0 - h)}{2h} + \frac{\delta_+ - \delta_-}{2h}. \tag{50}$$

Погрешность вычислений:

$$|E_{\text{выч}}| = \left|\frac{\delta_+ - \delta_-}{2h}\right| \le \frac{2\varepsilon}{2h} = \frac{\varepsilon}{h}. \tag{51}$$

4. Полная погрешность и оптимальный шаг

Полная погрешность численного дифференцирования складывается из погрешности метода и погрешности вычислений:

$$|E_{\text{полн}}| \le |E_{\text{мет}}| + |E_{\text{выч}}| \le \frac{h^2}{6} + \frac{\varepsilon}{h}. \tag{52}$$

Найдем оптимальный шаг h_{opt}, минимизирующий полную погрешность. Продифференцируем (52) по h и приравняем к нулю:

$$\frac{d|E_{\text{полн}}|}{dh} = \frac{h}{3} - \frac{\varepsilon}{h^2} = 0. \tag{53}$$

Отсюда:

$$h^3 = 3\varepsilon \implies \boxed{h_{\text{opt}} = (3\varepsilon)^{1/3}.} \tag{54}$$

5. Минимальная погрешность

Подставим h_{opt} в (52):

$$\begin{aligned} |E_{\min}| &= \frac{(3\varepsilon)^{2/3}}{6} + \frac{\varepsilon}{(3\varepsilon)^{1/3}} \\ &= \frac{(3\varepsilon)^{2/3}}{6} + \frac{(3\varepsilon)^{2/3}}{3} \\ &= (3\varepsilon)^{2/3}\left(\frac{1}{6} + \frac{1}{3}\right) \\ &= \frac{(3\varepsilon)^{2/3}}{2}. \end{aligned} \tag{55}$$

6. Численные оценки для различных точностей

Для одинарной точности ($\varepsilon \approx 10^{-7}$):

$$h_{\text{opt}} \approx (3 \cdot 10^{-7})^{1/3} \approx 6,7 \cdot 10^{-3}, \tag{56}$$

$$|E_{\min}| \approx \frac{(3 \cdot 10^{-7})^{2/3}}{2} \approx 2,2 \cdot 10^{-5}. \tag{57}$$

Для двойной точности ($\varepsilon \approx 10^{-16}$):

$$h_{\text{opt}} \approx (3 \cdot 10^{-16})^{1/3} \approx 6,7 \cdot 10^{-6}, \tag{58}$$

$$|E_{\min}| \approx \frac{(3 \cdot 10^{-16})^{2/3}}{2} \approx 2,2 \cdot 10^{-11}. \tag{59}$$

Итог

- Формула для вычисления $f'(x_0)$ со вторым порядком аппроксимации:

$$f'(x_0) \approx \frac{f(x_0 + h) - f(x_0 - h)}{2h}. \tag{60}$$

- Погрешность метода: $|E_{\text{мет}}| \leq h^2/6$.
- Оптимальный шаг: $h_{\text{opt}} = (3\varepsilon)^{1/3}$.
- Минимальная погрешность: $|E_{\min}| = (3\varepsilon)^{2/3}/2$.

Задача II.7.37 (пункт в)

Условие: Найти область сходимости метода Якоби и метода Зейделя для системы с матрицей вида:

$$\mathbf{A} = \begin{pmatrix} \alpha & \beta & 0 \\ \beta & \alpha & 0 \\ 0 & 0 & \alpha \end{pmatrix}. \tag{61}$$

Решение:

1. Предварительный анализ структуры матрицы

Матрица $\mathbf{A}$ имеет блочно-диагональную структуру:

$$\mathbf{A} = \begin{pmatrix} \mathbf{A}_{2\times 2} & \mathbf{0} \\ \mathbf{0} & \alpha \end{pmatrix}, \quad \text{где} \quad \mathbf{A}_{2\times 2} = \begin{pmatrix} \alpha & \beta \\ \beta & \alpha \end{pmatrix}. \tag{62}$$

Поскольку третья строка и третий столбец содержат только диагональный элемент α, третья компонента решения определяется независимо: $x_3 = f_3/\alpha$ (при $\alpha \neq 0$). Поэтому сходимость итерационных методов определяется только блоком 2×2 в верхнем левом углу.

Замечание: Блок $\mathbf{A}_{2\times 2}$ симметричен, поэтому согласно задаче II.7.39 методы Якоби и Зейделя для него сходятся и расходятся одновременно. Проверим это явно.

2. Метод Якоби

Разложим $\mathbf{A} = \mathbf{D} - \mathbf{L} - \mathbf{U}$:

$$\mathbf{D} = \begin{pmatrix} \alpha & 0 & 0 \\ 0 & \alpha & 0 \\ 0 & 0 & \alpha \end{pmatrix}, \quad \mathbf{L} = \begin{pmatrix} 0 & 0 & 0 \\ -\beta & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}, \quad \mathbf{U} = \begin{pmatrix} 0 & -\beta & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}. \tag{63}$$

Итерационная матрица метода Якоби:

$$\mathbf{R}_J = -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U}) = -\frac{1}{\alpha}\begin{pmatrix} 0 & -\beta & 0 \\ -\beta & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & \beta/\alpha & 0 \\ \beta/\alpha & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}. \tag{64}$$

Найдём собственные значения из характеристического уравнения $\det(\mathbf{R}_J - \lambda\mathbf{I}) = 0$:

$$\det\begin{pmatrix} -\lambda & \beta/\alpha & 0 \\ \beta/\alpha & -\lambda & 0 \\ 0 & 0 & -\lambda \end{pmatrix} = -\lambda\left(\lambda^2 - \frac{\beta^2}{\alpha^2}\right) = 0. \tag{65}$$

Собственные значения:

$$\lambda_1^{(J)} = 0, \quad \lambda_2^{(J)} = \frac{\beta}{\alpha}, \quad \lambda_3^{(J)} = -\frac{\beta}{\alpha}. \tag{66}$$

Спектральный радиус:

$$\rho(\mathbf{R}_J) = \left|\frac{\beta}{\alpha}\right|. \tag{67}$$

Метод Якоби сходится при $\rho(\mathbf{R}_J) < 1$, т.е.:

$$\boxed{|\beta| < |\alpha|.} \tag{68}$$

3. Метод Зейделя

Итерационная матрица метода Зейделя:

$$\mathbf{R}_S = -(\mathbf{D} + \mathbf{L})^{-1}\mathbf{U}. \tag{69}$$

Сначала найдём $(\mathbf{D} + \mathbf{L})^{-1}$:

$$\mathbf{D} + \mathbf{L} = \begin{pmatrix} \alpha & 0 & 0 \\ \beta & \alpha & 0 \\ 0 & 0 & \alpha \end{pmatrix}. \tag{70}$$

Это нижнетреугольная матрица, её обратная также нижнетреугольна:

$$(\mathbf{D} + \mathbf{L})^{-1} = \begin{pmatrix} 1/\alpha & 0 & 0 \\ -\beta/\alpha^2 & 1/\alpha & 0 \\ 0 & 0 & 1/\alpha \end{pmatrix}. \tag{71}$$

Теперь вычислим $\mathbf{R}_S$:

$$\begin{aligned} \mathbf{R}_S &= -\begin{pmatrix} 1/\alpha & 0 & 0 \\ -\beta/\alpha^2 & 1/\alpha & 0 \\ 0 & 0 & 1/\alpha \end{pmatrix}\begin{pmatrix} 0 & -\beta & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \\ &= -\begin{pmatrix} 0 & -\beta/\alpha & 0 \\ 0 & \beta^2/\alpha^2 & 0 \\ 0 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & \beta/\alpha & 0 \\ 0 & -\beta^2/\alpha^2 & 0 \\ 0 & 0 & 0 \end{pmatrix}. \end{aligned} \tag{72}$$

Матрица $\mathbf{R}_S$ верхнетреугольна, поэтому её собственные значения равны диагональным элементам:

$$\lambda_1^{(S)} = 0, \quad \lambda_2^{(S)} = -\frac{\beta^2}{\alpha^2}, \quad \lambda_3^{(S)} = 0. \tag{73}$$

Спектральный радиус:

$$\rho(\mathbf{R}_S) = \left(\frac{\beta}{\alpha}\right)^2 = \left[\rho(\mathbf{R}_J)\right]^2. \tag{74}$$

Метод Зейделя сходится при $\rho(\mathbf{R}_S) < 1$, т.е.:

$$\left(\frac{\beta}{\alpha}\right)^2 < 1 \iff \boxed{|\beta| < |\alpha|.} \tag{75}$$

4. Сравнение и вывод

Оба метода сходятся при одном и том же условии $|\beta| < |\alpha|$, что согласуется с результатом задачи II.7.39 для систем второго порядка (наш блок 2×2 симметричен).

При этом, если оба метода сходятся, метод Зейделя сходится **примерно в два раза быстрее** метода Якоби, поскольку:

$$\rho(\mathbf{R}_S) = [\rho(\mathbf{R}_J)]^2. \tag{76}$$

Например, при $\beta/\alpha = 0.9$:

- $\rho(\mathbf{R}_J) = 0.9$ (медленная сходимость),
- $\rho(\mathbf{R}_S) = 0.81$ (заметно быстрее).

Итог

- **Область сходимости метода Якоби:** $|\beta| < |\alpha|$.
- **Область сходимости метода Зейделя:** $|\beta| < |\alpha|$.
- Области сходимости совпадают.
- При сходимости метод Зейделя сходится быстрее (спектральный радиус в квадрате меньше).

Задача II.9.2 (пункт а)

Условие: Дана система линейных алгебраических уравнений $\mathbf{Ax} = \mathbf{b}$. Оценить максимально точную относительную погрешность $\|\Delta\mathbf{x}\|/\|\mathbf{x}\|$ в заданной норме. Найти вектор ошибки $\Delta\mathbf{b}$, на котором эта оценка достигается. При каком $\Delta\mathbf{b}$ относительная ошибка $\|\Delta\mathbf{x}\|/\|\mathbf{x}\|$ будет минимальной? Найти её.

$$\mathbf{A} = \begin{pmatrix} 101 & 110 \\ 110 & 122 \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} 312 \\ 342 \end{pmatrix}, \quad \frac{\|\Delta\mathbf{b}\|}{\|\mathbf{b}\|} = 0{,}01, \quad \|\mathbf{x}\| = \max_i |x_i|.$$

Примечание: индекс “1” в обозначении нормы — это номер варианта задачи, а не первая норма. Формула $\|\mathbf{x}\| = \max_i |x_i|$ задаёт чебышёвскую норму $\|\cdot\|_\infty$.

Решение:

1. Решение системы $\mathbf{Ax} = \mathbf{b}$

Найдём определитель матрицы $\mathbf{A}$:

$$\det(\mathbf{A}) = 101 \cdot 122 - 110 \cdot 110 = 12322 - 12100 = 222. \tag{77}$$

Обратная матрица:

$$\mathbf{A}^{-1} = \frac{1}{222} \begin{pmatrix} 122 & -110 \\ -110 & 101 \end{pmatrix}. \tag{78}$$

Решение системы $\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}$:

$$\mathbf{x} = \frac{1}{222} \begin{pmatrix} 122 & -110 \\ -110 & 101 \end{pmatrix} \begin{pmatrix} 312 \\ 342 \end{pmatrix} = \frac{1}{222} \begin{pmatrix} 122 \cdot 312 - 110 \cdot 342 \\ -110 \cdot 312 + 101 \cdot 342 \end{pmatrix} = \frac{1}{222} \begin{pmatrix} 38064 - 37620 \\ -34320 + 34542 \end{pmatrix} = \frac{1}{222} \begin{pmatrix} 444 \\ 222 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}. \tag{79}$$

Итак, точное решение: $\mathbf{x} = (2, 1)^T$.

2. Вычисление норм в $\|\cdot\|_\infty$

Норма вектора $\mathbf{x}$ (максимум модулей компонент):

$$\|\mathbf{x}\|_\infty = \max(|2|, |1|) = 2. \tag{80}$$

Норма вектора $\mathbf{b}$:

$$\|\mathbf{b}\|_\infty = \max(|312|, |342|) = 342. \tag{81}$$

Абсолютная погрешность правой части:

$$\|\Delta\mathbf{b}\|_\infty = 0{,}01 \cdot \|\mathbf{b}\|_\infty = 0{,}01 \cdot 342 = 3{,}42. \tag{82}$$

Норма матрицы $\mathbf{A}$ в ∞-норме (максимум сумм модулей элементов по **строкам**):

$$\|\mathbf{A}\|_\infty = \max\big(|101| + |110|,\ |110| + |122|\big) = \max(211,\ 232) = 232. \tag{83}$$

Норма обратной матрицы:

$$\|\mathbf{A}^{-1}\|_\infty = \frac{1}{222} \max\big(|122| + |-110|,\ |-110| + |101|\big) = \frac{1}{222} \max(232,\ 211) = \frac{232}{222} = \frac{116}{111}. \tag{84}$$

3. Число обусловленности и теоретическая оценка погрешности

Число обусловленности матрицы $\mathbf{A}$:

$$\operatorname{cond}(\mathbf{A}) = \|\mathbf{A}\|_\infty \cdot \|\mathbf{A}^{-1}\|_\infty = 232 \cdot \frac{232}{222} = \frac{53824}{222} = \frac{26912}{111} \approx 242{,}45. \tag{85}$$

Стандартная оценка даёт верхнюю границу:

$$\frac{\|\Delta\mathbf{x}\|_\infty}{\|\mathbf{x}\|_\infty} \leqslant \operatorname{cond}(\mathbf{A}) \cdot \frac{\|\Delta\mathbf{b}\|_\infty}{\|\mathbf{b}\|_\infty} = \frac{26912}{111} \cdot 0{,}01 \approx 2{,}4245. \tag{86}$$

Эта оценка достижима только при "худшем" $\mathbf{b}$. Поскольку наш $\mathbf{b}$ фиксирован, найдём точный максимум через **естественное число обусловленности**:

$$\nu(\mathbf{A}, \mathbf{b}) = \frac{\|\mathbf{A}^{-1}\|_\infty \cdot \|\mathbf{b}\|_\infty}{\|\mathbf{A}^{-1}\mathbf{b}\|_\infty} = \frac{\|\mathbf{A}^{-1}\|_\infty \cdot \|\mathbf{b}\|_\infty}{\|\mathbf{x}\|_\infty} = \frac{\frac{232}{222} \cdot 342}{2} = \frac{232 \cdot 342}{222 \cdot 2} = \frac{79344}{444} = \frac{19836}{111} \approx 178{,}70. \tag{87}$$

Точная максимальная оценка:

$$\frac{\|\Delta\mathbf{x}\|_\infty}{\|\mathbf{x}\|_\infty} \leqslant \nu(\mathbf{A}, \mathbf{b}) \cdot \frac{\|\Delta\mathbf{b}\|_\infty}{\|\mathbf{b}\|_\infty} = \frac{19836}{111} \cdot 0{,}01 = \frac{198{,}36}{111} \approx 1{,}787. \tag{88}$$

4. Вектор Δb, на котором достигается максимум

В ∞-норме максимум $\|\mathbf{A}^{-1}\Delta\mathbf{b}\|_\infty / \|\Delta\mathbf{b}\|_\infty$ достигается на векторе $\Delta\mathbf{b}$, знаки компонент которого совпадают со знаками элементов **строки** матрицы $\mathbf{A}^{-1}$ с наибольшей суммой модулей.

Анализируем строки $\mathbf{A}^{-1} = \frac{1}{222}\begin{pmatrix} 122 & -110 \\ -110 & 101 \end{pmatrix}$:

- Первая строка: $|122| + |-110| = 232$ (максимум).
- Вторая строка: $|-110| + |101| = 211$.

Первая строка даёт максимум. Её элементы имеют знаки $(+, -)$, поэтому оптимальное направление:

$$\Delta\mathbf{b}_{\max} = \pm\|\Delta\mathbf{b}\|_\infty \cdot \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \pm 3{,}42 \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \pm \begin{pmatrix} 3{,}42 \\ -3{,}42 \end{pmatrix}. \tag{89}$$

Проверка. При $\Delta\mathbf{b} = (3{,}42; -3{,}42)^T$:

$$\Delta\mathbf{x} = \mathbf{A}^{-1}\Delta\mathbf{b} = \frac{3{,}42}{222}\begin{pmatrix} 122 & -110 \\ -110 & 101 \end{pmatrix}\begin{pmatrix} 1 \\ -1 \end{pmatrix} = \frac{3{,}42}{222}\begin{pmatrix} 122 + 110 \\ -110 - 101 \end{pmatrix} = \frac{3{,}42}{222}\begin{pmatrix} 232 \\ -211 \end{pmatrix}. \tag{90}$$

$$\|\Delta\mathbf{x}\|_\infty = \frac{3{,}42}{222} \cdot 232 = \frac{3{,}42 \cdot 232}{222} \approx 3{,}574. \tag{91}$$

$$\frac{\|\Delta\mathbf{x}\|_\infty}{\|\mathbf{x}\|_\infty} = \frac{3{,}574}{2} \approx 1{,}787. \quad \checkmark \tag{92}$$

5. Минимальная погрешность

Тривиальный случай: при $\Delta\mathbf{b} = \mathbf{0}$ погрешность равна нулю.

Нетривиальный случай: найдём минимум $\|\mathbf{A}^{-1}\Delta\mathbf{b}\|_\infty / \|\Delta\mathbf{b}\|_\infty$.

Для ∞-нормы минимум достигается на векторе $\Delta\mathbf{b}$, который "аннигилирует" строку матрицы $\mathbf{A}^{-1}$ с максимальной суммой модулей, то есть делает первую компоненту $\mathbf{A}^{-1}\Delta\mathbf{b}$ равной нулю.

Условие: $122 \cdot \Delta b_1 - 110 \cdot \Delta b_2 = 0 \implies \Delta b_1 / \Delta b_2 = 110/122 = 55/61$.

Нормируем в ∞-норме: $\|\Delta\mathbf{b}\|_\infty = 3{,}42$, поэтому $\Delta b_2 = 3{,}42$, $\Delta b_1 = 3{,}42 \cdot 55/61 \approx 3{,}089$.

$$\Delta\mathbf{b}_{\min} = \pm 3{,}42 \begin{pmatrix} 55/61 \\ 1 \end{pmatrix} \approx \pm \begin{pmatrix} 3{,}089 \\ 3{,}42 \end{pmatrix}. \tag{93}$$

Проверка. Вычислим $\mathbf{A}^{-1}\Delta\mathbf{b}_{\min}$:

$$\mathbf{A}^{-1}\begin{pmatrix} 55/61 \\ 1 \end{pmatrix} = \frac{1}{222}\begin{pmatrix} 122 \cdot \frac{55}{61} - 110 \\ -110 \cdot \frac{55}{61} + 101 \end{pmatrix} = \frac{1}{222}\begin{pmatrix} 110 - 110 \\ -\frac{6050}{61} + 101 \end{pmatrix} = \frac{1}{222}\begin{pmatrix} 0 \\ \frac{-6050+6161}{61} \end{pmatrix} = \frac{1}{222}\begin{pmatrix} 0 \\ \frac{111}{61} \end{pmatrix} = \begin{pmatrix} 0 \\ \frac{1}{122} \end{pmatrix}. \tag{94}$$

Значит,

$$\Delta\mathbf{x} = 3{,}42\begin{pmatrix} 0 \\ 1/122 \end{pmatrix}, \quad \|\Delta\mathbf{x}\|_\infty = \frac{3{,}42}{122} \approx 0{,}02803. \tag{95}$$

$$\frac{\|\Delta\mathbf{x}\|_\infty}{\|\mathbf{x}\|_\infty} = \frac{0{,}02803}{2} \approx 0{,}01402. \tag{96}$$

Итог

- Решение системы: $\mathbf{x} = (2,\ 1)^T$.
- Теоретическая оценка через $\mathrm{cond}(\mathbf{A})$: $\|\Delta\mathbf{x}\|_\infty / \|\mathbf{x}\|_\infty \leqslant 2{,}42$ ($\approx 242\%$) — достижима только при "худшем" $\mathbf{b}$.
- Реальный максимум при данном $\mathbf{b}$: $\approx 1{,}787$ ($\approx 178{,}7\%$), достигается на $\Delta\mathbf{b} = \pm(3{,}42;\ -3{,}42)^T$.
- Минимальная ненулевая погрешность: $\approx 0{,}014$ ($\approx 1{,}4\%$), достигается на $\Delta\mathbf{b} \propto (55;\ 61)^T$.

Физический смысл: матрица $\mathbf{A}$ плохо обусловлена ($\mathrm{cond} \approx 242$). В "худшем" направлении ошибка правой части усиливается в ~ 179 раз (с учётом конкретного $\mathbf{b}$), а в "лучшем" — почти не усиливается (коэффициент $\approx 1{,}4$). Вектор $\mathbf{b} = (312, 342)^T$ близок к "худшему" направлению, поэтому реальная максимальная погрешность $\approx 179\%$ близка к теоретическому максимуму 242%.

Задача II.9.14

Условие: Система уравнений $\mathbf{Ax} = \mathbf{f}$, где

$$\mathbf{A} = \begin{pmatrix} 3 & -1 & 1 \\ 2 & 6 & -2 \\ -1 & 1 & 9 \end{pmatrix}, \quad \mathbf{f} = (4, -4, 2)^T,$$

решается с помощью метода простых итераций, начальное приближение нулевое. При каких значениях итерационного параметра метод будет сходиться:

а) при вычислениях с бесконечным числом бит в мантиссе?

б) при длине мантиссы 52 бита?

в) при каком значении итерационного параметра сходимость будет самая быстрая?

г) Найти значение оптимального параметра для первого шага решения системы методом наискорейшего спуска.

Решение:

Предварительный анализ: собственные значения матрицы A

Метод простых итераций с параметром τ имеет вид:

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \tau(\mathbf{A}\mathbf{x}^{(k)} - \mathbf{f}) = (\mathbf{I} - \tau\mathbf{A})\mathbf{x}^{(k)} + \tau\mathbf{f}. \tag{97}$$

Итерационная матрица: $\mathbf{B}(\tau) = \mathbf{I} - \tau\mathbf{A}$.

Метод сходится тогда и только тогда, когда спектральный радиус $\rho(\mathbf{B}(\tau)) < 1$.

Найдём собственные значения матрицы $\mathbf{A}$ из характеристического уравнения $\det(\mathbf{A} - \lambda\mathbf{I}) = 0$:

$$\det \begin{pmatrix} 3-\lambda & -1 & 1 \\ 2 & 6-\lambda & -2 \\ -1 & 1 & 9-\lambda \end{pmatrix} = 0. \tag{98}$$

Раскрывая определитель:

$$\begin{aligned} &(3-\lambda)[(6-\lambda)(9-\lambda)+2] + [2(9-\lambda)-2] + [2+(6-\lambda)] \\ &= (3-\lambda)(\lambda^2 - 15\lambda + 56) + (16 - 2\lambda) + (8 - \lambda) \\ &= -\lambda^3 + 18\lambda^2 - 104\lambda + 192 = 0. \end{aligned} \tag{99}$$

Проверяем $\lambda = 4$: $-64 + 288 - 416 + 192 = 0$

Делим на $(\lambda - 4)$: $\lambda^3 - 18\lambda^2 + 104\lambda - 192 = (\lambda - 4)(\lambda^2 - 14\lambda + 48) = 0$.

Корни квадратного уравнения: $\lambda = \frac{14 \pm \sqrt{196 - 192}}{2} = \frac{14 \pm 2}{2}$, т.е. $\lambda = 8$ и $\lambda = 6$.

Собственные значения матрицы A: $\lambda_1 = 4$, $\lambda_2 = 6$, $\lambda_3 = 8$.

Собственные значения итерационной матрицы $\mathbf{B}(\tau) = \mathbf{I} - \tau\mathbf{A}$:

$$\mu_1 = 1 - 4\tau, \quad \mu_2 = 1 - 6\tau, \quad \mu_3 = 1 - 8\tau. \tag{100}$$

а) Сходимость при бесконечной точности

Метод сходится при $\rho(\mathbf{B}(\tau)) = \max(|\mu_1|, |\mu_2|, |\mu_3|) < 1$:

$$|1 - 4\tau| < 1 \implies 0 < \tau < \frac{1}{2}, \tag{101}$$

$$|1 - 6\tau| < 1 \implies 0 < \tau < \frac{1}{3}, \tag{102}$$

$$|1 - 8\tau| < 1 \implies 0 < \tau < \frac{1}{4}. \tag{103}$$

Пересечение условий:

$$\boxed{0 < \tau < \frac{1}{4}.} \tag{104}$$

б) Сходимость при длине мантиссы 52 бита

При конечной точности вычислений (double precision, $\varepsilon_{\text{маш}} = 2^{-52} \approx 2.22 \cdot 10^{-16}$) метод сходится к окрестности точного решения, если $\rho(\mathbf{B}(\tau)) < 1$. Однако при τ, близком к границам интервала $(0, 1/4)$, спектральный радиус близок к 1, и сходимость становится чрезвычайно медленной.

Практически метод сходится за разумное число итераций, если $\rho(\mathbf{B}(\tau)) < 1 - c\varepsilon_{\text{маш}}$ для некоторой константы c. Это исключает малые окрестности точек $\tau = 0$ и $\tau = 1/4$.

Формально условие сходимости остаётся тем же:

$$\boxed{0 < \tau < \frac{1}{4},} \tag{105}$$

но практически следует выбирать τ подальше от границ, например $\tau \in (10^{-15}, 1/4 - 10^{-15})$.

в) Оптимальный параметр для максимальной скорости сходимости

Нужно минимизировать $\rho(\mathbf{B}(\tau)) = \max(|1 - 4\tau|, |1 - 6\tau|, |1 - 8\tau|)$.

При $\tau \in (0, 1/4)$:

- $1 - 4\tau$ убывает от 1 до 0,
- $1 - 6\tau$ убывает от 1 до $-1/2$,
- $1 - 8\tau$ убывает от 1 до -1.

Максимум по модулю определяется крайними собственными значениями: $\max(|1 - 4\tau|, |1 - 8\tau|)$.

Оптимум достигается, когда $|1 - 4\tau| = |1 - 8\tau|$:

$$1 - 4\tau = -(1 - 8\tau) \implies 2 = 12\tau \implies \tau_{\text{opt}} = \frac{1}{6}. \tag{106}$$

При $\tau = 1/6$:

$$\mu_1 = 1 - 4 \cdot \frac{1}{6} = \frac{1}{3}, \tag{107}$$

$$\mu_2 = 1 - 6 \cdot \frac{1}{6} = 0, \tag{108}$$

$$\mu_3 = 1 - 8 \cdot \frac{1}{6} = -\frac{1}{3}. \tag{109}$$

$$\boxed{\tau_{\text{opt}} = \frac{1}{6}, \quad \rho(\mathbf{B}(\tau_{\text{opt}})) = \frac{1}{3}.} \tag{110}$$

г) Оптимальный параметр для первого шага метода наискорейшего спуска

При $\mathbf{x}^{(0)} = \mathbf{0}$: невязка $\mathbf{r}^{(0)} = \mathbf{f} - \mathbf{A}\mathbf{x}^{(0)} = \mathbf{f} = (4, -4, 2)^T$.

Метод наискорейшего спуска: $\mathbf{x}^{(1)} = \mathbf{x}^{(0)} + \tau_0 \mathbf{r}^{(0)} = \tau_0 \mathbf{f}$.

Оптимальный τ_0 минимизирует $\|\mathbf{r}^{(1)}\|^2 = \|\mathbf{f} - \mathbf{A}\mathbf{x}^{(1)}\|^2 = \|\mathbf{f} - \tau_0 \mathbf{A}\mathbf{f}\|^2$.

Условие минимума: $\frac{d}{d\tau_0}\|\mathbf{f} - \tau_0 \mathbf{A}\mathbf{f}\|^2 = -2(\mathbf{f} - \tau_0 \mathbf{A}\mathbf{f}, \mathbf{A}\mathbf{f}) = 0$.

Отсюда:

$$\tau_0 = \frac{(\mathbf{f}, \mathbf{Af})}{(\mathbf{Af}, \mathbf{Af})} = \frac{(\mathbf{f}, \mathbf{Af})}{\|\mathbf{Af}\|^2}. \tag{111}$$

Вычислим $\mathbf{Af}$:

$$\mathbf{Af} = \begin{pmatrix} 3 & -1 & 1 \\ 2 & 6 & -2 \\ -1 & 1 & 9 \end{pmatrix} \begin{pmatrix} 4 \\ -4 \\ 2 \end{pmatrix} = \begin{pmatrix} 12+4+2 \\ 8-24-4 \\ -4-4+18 \end{pmatrix} = \begin{pmatrix} 18 \\ -20 \\ 10 \end{pmatrix}. \tag{112}$$

Скалярное произведение $(\mathbf{f}, \mathbf{Af})$:

$$(\mathbf{f}, \mathbf{Af}) = 4 \cdot 18 + (-4) \cdot (-20) + 2 \cdot 10 = 72 + 80 + 20 = 172. \tag{113}$$

Квадрат нормы $\|\mathbf{Af}\|^2$:

$$\|\mathbf{Af}\|^2 = 18^2 + (-20)^2 + 10^2 = 324 + 400 + 100 = 824. \tag{114}$$

Оптимальный параметр:

$$\boxed{\tau_0 = \frac{172}{824} = \frac{43}{206} \approx 0,2087.} \tag{115}$$

Итог

- а) Метод сходится при $0 < \tau < 1/4$.
- б) При конечной точности формально условие то же, но практически следует избегать τ близких к 0 и $1/4$.
- в) Оптимальный параметр $\tau_{\text{opt}} = 1/6$, спектральный радиус $\rho = 1/3$.
- г) Для первого шага метода наискорейшего спуска $\tau_0 = 43/206 \approx 0,2087$.

Задача III.4.3

Условие: Предложить алгоритм проведения на плоскости окружности через четыре и более точек методом наименьших квадратов.

Решение:

1. Постановка задачи

Пусть на плоскости заданы N точек с координатами (x_i, y_i), $i = 1, 2, \ldots, N$, причём $N \geqslant 4$. Требуется найти окружность, которая наилучшим образом (в смысле метода наименьших квадратов) аппроксимирует эти точки.

Уравнение окружности с центром в точке (a, b) и радиусом R имеет вид:

$$(x - a)^2 + (y - b)^2 = R^2. \tag{116}$$

Раскроем скобки:

$$x^2 - 2ax + a^2 + y^2 - 2by + b^2 = R^2. \tag{117}$$

Перегруппируем слагаемые, перенеся всё, что зависит от координат точки, в правую часть:

$$2ax + 2by + (R^2 - a^2 - b^2) = x^2 + y^2. \tag{118}$$

Введём обозначение $c = R^2 - a^2 - b^2$. Тогда уравнение окружности принимает вид:

$$2ax + 2by + c = x^2 + y^2. \tag{119}$$

Ключевое наблюдение: уравнение (119) линейно относительно неизвестных параметров a, b и c. Это позволяет свести задачу к решению переопределённой системы линейных алгебраических уравнений (СЛАУ).

2. Составление переопределённой СЛАУ

Подставим координаты каждой из N заданных точек в уравнение (119). Получим систему:

$$\begin{cases} 2ax_1 + 2by_1 + c = x_1^2 + y_1^2, \\ 2ax_2 + 2by_2 + c = x_2^2 + y_2^2, \\ \quad\vdots \\ 2ax_N + 2by_N + c = x_N^2 + y_N^2. \end{cases} \tag{120}$$

В матричной форме эта система записывается как:

$$\mathbf{G}\boldsymbol{\theta} = \mathbf{f}, \tag{121}$$

где

$$\mathbf{G} = \begin{pmatrix} 2x_1 & 2y_1 & 1 \\ 2x_2 & 2y_2 & 1 \\ \vdots & \vdots & \vdots \\ 2x_N & 2y_N & 1 \end{pmatrix}, \quad \boldsymbol{\theta} = \begin{pmatrix} a \\ b \\ c \end{pmatrix}, \quad \mathbf{f} = \begin{pmatrix} x_1^2 + y_1^2 \\ x_2^2 + y_2^2 \\ \vdots \\ x_N^2 + y_N^2 \end{pmatrix}. \tag{122}$$

Поскольку $N \geqslant 4 > 3$, система (121) является переопределённой и, вообще говоря, не имеет точного решения.

3. Метод наименьших квадратов

Вместо точного решения будем искать вектор $\boldsymbol{\theta}$, минимизирующий квадрат евклидовой нормы невязки:

$$\Phi(\boldsymbol{\theta}) = \|\mathbf{G}\boldsymbol{\theta} - \mathbf{f}\|_2^2 = \sum_{i=1}^{N} \bigl(2ax_i + 2by_i + c - (x_i^2 + y_i^2)\bigr)^2 \to \min. \tag{123}$$

Необходимое условие минимума — обращение в нуль градиента Φ по всем компонентам $\boldsymbol{\theta}$:

$$\frac{\partial \Phi}{\partial \boldsymbol{\theta}} = 2\mathbf{G}^T(\mathbf{G}\boldsymbol{\theta} - \mathbf{f}) = \mathbf{0}. \tag{124}$$

Отсюда получаем **нормальную систему** уравнений:

$$\mathbf{G}^T\mathbf{G}\boldsymbol{\theta} = \mathbf{G}^T\mathbf{f}. \tag{125}$$

Матрица $\mathbf{G}^T\mathbf{G}$ имеет размер 3×3. Если точки не лежат на одной прямой, эта матрица невырождена, и решение единственно:

$$\boldsymbol{\theta} = (\mathbf{G}^T\mathbf{G})^{-1}\mathbf{G}^T\mathbf{f}. \tag{126}$$

4. Восстановление радиуса

После того как найдены параметры a, b, c, радиус окружности восстанавливается из соотношения $c = R^2 - a^2 - b^2$:

$$R = \sqrt{a^2 + b^2 + c}. \tag{127}$$

5. Итоговый алгоритм

1. **Входные данные:** координаты N точек (x_i, y_i), $i = 1, \ldots, N$, $N \geqslant 4$.
2. **Шаг 1.** Сформировать матрицу $\mathbf{G}$ размера $N \times 3$ и вектор $\mathbf{f}$ длины N:
$$G_{i1} = 2x_i, \quad G_{i2} = 2y_i, \quad G_{i3} = 1, \quad f_i = x_i^2 + y_i^2. \tag{128}$$
3. **Шаг 2.** Вычислить матрицу $\mathbf{A} = \mathbf{G}^T\mathbf{G}$ размера 3×3 и вектор $\mathbf{b} = \mathbf{G}^T\mathbf{f}$ длины 3.
4. **Шаг 3.** Решить нормальную систему $\mathbf{A}\boldsymbol{\theta} = \mathbf{b}$ относительно $\boldsymbol{\theta} = (a, b, c)^T$.
5. **Шаг 4.** Вычислить радиус: $R = \sqrt{a^2 + b^2 + c}$.
6. **Выходные данные:** центр окружности (a, b) и радиус R.

6. Замечание о численной устойчивости

На практике для повышения численной устойчивости алгоритма рекомендуется перед построением матрицы $\mathbf{G}$ выполнить центрирование данных: вычесть из всех координат x_i и y_i их средние значения $\bar{x}$ и $\bar{y}$. После нахождения параметров в центрированной системе координат центр окружности пересчитывается обратно: $a_{\text{исх}} = a + \bar{x}$, $b_{\text{исх}} = b + \bar{y}$.

Задача III.4.4

Условие: Напряжённость магнитного поля H и магнитная индукция B связаны соотношением $B = H/(a + bH)$. По результатам экспериментальных измерений определить коэффициенты a и b:

H	8	10	15	20	30	40	60	80
B	13,0	14,0	15,4	16,3	17,2	17,8	18,5	18,8

Решение:

1. Теоретическое обоснование метода итерированного веса

Исходная задача состоит в минимизации нелинейного функционала невязки:

$$\Phi(a, b) = \sum_{i=1}^{N} \left(B_i - \frac{H_i}{a + bH_i} \right)^2 \to \min . \tag{129}$$

Прямая минимизация (129) приводит к системе нелинейных уравнений. Чтобы свести задачу к линейной, выполним алгебраическое преобразование *внутри* квадрата невязки. Приведём выражение в скобках к общему знаменателю:

$$B_i - \frac{H_i}{a + bH_i} = \frac{aB_i + bB_iH_i - H_i}{a + bH_i}. \tag{130}$$

Подставим это обратно в функционал (129):

$$\Phi(a, b) = \sum_{i=1}^{N} \frac{(aB_i + bB_iH_i - H_i)^2}{(a + bH_i)^2} = \sum_{i=1}^{N} w_i(a, b) \cdot (aB_i + bB_iH_i - H_i)^2 \to \min, \tag{131}$$

где введены **веса**:

$$w_i(a, b) = \frac{1}{(a + bH_i)^2}. \tag{132}$$

Формула (131) представляет собой задачу **взвешенного метода наименьших квадратов (ВМНК)** для линейного уравнения $aB_i + bB_iH_i = H_i$. Однако веса w_i зависят от искомых параметров a и b, поэтому мы не можем решить эту систему за один шаг. Для этого применяется **метод итерированного веса** (Iteratively Reweighted Least Squares, IRLS).

2. Алгоритм метода итерированного веса

1. **Нулевая итерация (начальное приближение):** Решаем задачу *невзвешенного* МНК (полагая $w_i^{(0)} = 1$), чтобы получить начальные оценки a_0 и b_0.
2. **k-я итерация:**
   (a) Вычисляем веса на основе предыдущих оценок: $w_i^{(k)} = \frac{1}{(a_{k-1} + b_{k-1}H_i)^2}$.
   (b) Решаем взвешенную нормальную систему:

$$\begin{cases} a \sum w_i^{(k)} B_i^2 + b \sum w_i^{(k)} B_i^2 H_i = \sum w_i^{(k)} B_i H_i, \\ a \sum w_i^{(k)} B_i^2 H_i + b \sum w_i^{(k)} B_i^2 H_i^2 = \sum w_i^{(k)} B_i H_i^2. \end{cases} \tag{133}$$

   (c) Получаем новые оценки a_k и b_k.
3. **Критерий остановки:** Повторяем шаг 2 до тех пор, пока изменения параметров $|a_k - a_{k-1}|$ и $|b_k - b_{k-1}|$ не станут меньше заданной точности (например, 10^{-4}).

3. Численная реализация

Шаг 0. Невзвешенное начальное приближение. Решая систему с $w_i = 1$ (как в классическом линейном МНК), получаем:

$$a_0 \approx 0{,}218, \quad b_0 \approx 0{,}0506. \tag{134}$$

Шаг 1. Первая итерация с весами. Вычислим веса $w_i^{(1)} = \frac{1}{(0{,}218 + 0{,}0506 \cdot H_i)^2}$ для каждой точки:

H_i	$a_0 + b_0 H_i$	$w_i^{(1)}$	$w_i^{(1)} B_i^2$
8	0,623	2,57	434,3
10	0,724	1,91	374,4
15	0,977	1,05	248,9
20	1,230	0,66	174,9
30	1,736	0,33	97,4
40	2,242	0,20	63,2
60	3,254	0,09	30,8
80	4,266	0,05	17,7

Подставляя эти веса в нормальную систему, вычисляем суммы:

$$\sum w_i B_i^2 \approx 1441,6, \qquad \sum w_i B_i^2 H_i \approx 23177,$$
$$\sum w_i B_i^2 H_i^2 \approx 606100, \qquad \sum w_i B_i H_i \approx 1477,$$
$$\sum w_i B_i H_i^2 \approx 35456.$$

Решаем систему:

$$\begin{pmatrix} 1441{,}6 & 23177 \\ 23177 & 606100 \end{pmatrix} \begin{pmatrix} a_1 \\ b_1 \end{pmatrix} = \begin{pmatrix} 1477 \\ 35456 \end{pmatrix}. \tag{135}$$

Определитель системы $\Delta \approx 3{,}36 \cdot 10^8$. Находим:

$$a_1 = \frac{1477 \cdot 606100 - 23177 \cdot 35456}{\Delta} \approx 0{,}218, \quad b_1 = \frac{1441{,}6 \cdot 35456 - 1477 \cdot 23177}{\Delta} \approx 0{,}0501. \tag{136}$$

Шаг 2 и далее. Повторение процедуры с новыми весами $w_i^{(2)} = \frac{1}{(0{,}218+0{,}0501 \cdot H_i)^2}$ показывает, что значения a и b практически перестают меняться (изменения меньше 10^{-4}). Метод сошёлся.

4. Итоговые результаты и проверка

Оптимальные значения коэффициентов:

$$\boxed{a \approx 0{,}218, \quad b \approx 0{,}0501.} \tag{137}$$

Уравнение кривой намагничивания:

$$B = \frac{H}{0{,}218 + 0{,}0501 H}. \tag{138}$$

Проверим качество аппроксимации, вычислив невязки $\Delta B_i = B_{i,\text{изм}} - B_{i,\text{расч}}$:

H	$B_{\text{изм}}$	$B_{\text{расч}}$	Невязка ΔB
8	13,0	12,93	+0,07
10	14,0	13,88	+0,12
15	15,4	15,38	+0,02
20	16,3	16,30	0,00
30	17,2	17,31	-0,11
40	17,8	17,86	-0,06
60	18,5	18,46	+0,04
80	18,8	18,77	+0,03

Сумма невязок близка к нулю ($\sum \Delta B_i \approx 0{,}11$), а максимальное отклонение не превышает 0,12 (менее 1% от максимального значения B).

5. Физическая интерпретация

- Параметр $a \approx 0{,}218$ определяет начальную магнитную проницаемость: $\mu_0 \approx 1/a \approx 4{,}6$.
- Параметр $b \approx 0{,}0501$ определяет уровень магнитного насыщения: $B_{\text{нас}} = 1/b \approx 19{,}96$ Тл, что полностью согласуется с поведением ферромагнетиков при больших H.

Задача III.4.8

Условие: Пусть замеры функции $y = f(x)$ осуществлены в точках $x_k = \cos\frac{\pi(1+2k)}{2(n+1)}$, $k = 0, 1, \ldots, n$, являющихся нулями многочлена Чебышёва $T_{n+1}(x)$, и собраны в таблицу. Среди многочленов степени не выше заданного k, $0 \le k \le n$, указать тот многочлен $P_k(x)$, который наилучшим (в смысле метода наименьших квадратов) образом приближает заданную функцию.

Провести вычисления в случае $n = 3$:

x	x_0	x_1	x_2	x_3
y	2	1	3	0

Решение:

1. Теоретическая часть

Ищем приближающий многочлен в виде разложения по многочленам Чебышёва:

$$P_k(x) = \sum_{j=0}^{k} C_j T_j(x), \quad 0 \le k \le n. \tag{139}$$

Функционал метода наименьших квадратов имеет вид:

$$\Phi(C_0, C_1, \ldots, C_k) = \sum_{m=0}^{n} \left(y_m - \sum_{j=0}^{k} C_j T_j(x_m) \right)^2 \to \min. \tag{140}$$

Ключевое свойство, на которое указывает условие задачи: многочлены Чебышёва $T_j(x)$ образуют **ортогональную систему** на множестве нулей $T_{n+1}(x)$ с единичными весами. А именно, для $x_m = \cos\frac{\pi(1+2m)}{2(n+1)}$ выполняется:

$$\sum_{m=0}^{n} T_i(x_m) T_j(x_m) = \begin{cases} 0, & i \ne j, \\ n+1, & i = j = 0, \\ \frac{n+1}{2}, & i = j \ne 0. \end{cases} \tag{141}$$

Благодаря ортогональности (141) нормальная система МНК **диагонализируется**, и каждый коэффициент C_j находится независимо из условия $\frac{\partial \Phi}{\partial C_j} = 0$:

$$C_j = \frac{\sum\limits_{m=0}^{n} y_m T_j(x_m)}{\sum\limits_{m=0}^{n} T_j^2(x_m)}. \tag{142}$$

Подставляя значения норм из (141), получаем явные формулы:

$$C_0 = \frac{1}{n+1} \sum_{m=0}^{n} y_m, \qquad C_j = \frac{2}{n+1} \sum_{m=0}^{n} y_m T_j(x_m), \quad j = 1, 2, \ldots, k. \tag{143}$$

2. Вычисления для $n = 3$

Узлы интерполяции — нули многочлена $T_4(x)$:

$$x_m = \cos\frac{\pi(1+2m)}{8}, \quad m = 0, 1, 2, 3. \tag{144}$$

Выпишем их явно:

$$x_0 = \cos\frac{\pi}{8} = \frac{\sqrt{2+\sqrt{2}}}{2} \approx 0{,}92388, \tag{145}$$

$$x_1 = \cos\frac{3\pi}{8} = \frac{\sqrt{2-\sqrt{2}}}{2} \approx 0{,}38268, \tag{146}$$

$$x_2 = \cos\frac{5\pi}{8} = -\frac{\sqrt{2-\sqrt{2}}}{2} \approx -0{,}38268, \tag{147}$$

$$x_3 = \cos\frac{7\pi}{8} = -\frac{\sqrt{2+\sqrt{2}}}{2} \approx -0{,}92388. \tag{148}$$

Значения многочленов Чебышёва $T_j(x_m) = \cos\frac{j\pi(1+2m)}{8}$ в узлах:

	$m=0$	$m=1$	$m=2$	$m=3$
$T_0(x_m)$	1	1	1	1
$T_1(x_m)$	$\cos\frac{\pi}{8}$	$\cos\frac{3\pi}{8}$	$-\cos\frac{3\pi}{8}$	$-\cos\frac{\pi}{8}$
$T_2(x_m)$	$\cos\frac{\pi}{4}=\frac{\sqrt{2}}{2}$	$\cos\frac{3\pi}{4}=-\frac{\sqrt{2}}{2}$	$\cos\frac{5\pi}{4}=-\frac{\sqrt{2}}{2}$	$\cos\frac{7\pi}{4}=\frac{\sqrt{2}}{2}$
$T_3(x_m)$	$\cos\frac{3\pi}{8}$	$-\cos\frac{\pi}{8}$	$\cos\frac{\pi}{8}$	$-\cos\frac{3\pi}{8}$

Коэффициент C_0:

$$C_0 = \frac{1}{4}(y_0+y_1+y_2+y_3) = \frac{1}{4}(2+1+3+0) = \frac{3}{2}. \tag{149}$$

Коэффициент C_1:

$$\begin{aligned} C_1 &= \frac{2}{4}\sum_{m=0}^{3} y_m T_1(x_m) = \frac{1}{2}\left(2\cos\frac{\pi}{8} + 1\cdot\cos\frac{3\pi}{8} + 3\cdot\left(-\cos\frac{3\pi}{8}\right) + 0\cdot\left(-\cos\frac{\pi}{8}\right)\right) \\ &= \frac{1}{2}\left(2\cos\frac{\pi}{8} - 2\cos\frac{3\pi}{8}\right) = \cos\frac{\pi}{8} - \cos\frac{3\pi}{8} = \frac{\sqrt{2+\sqrt{2}}-\sqrt{2-\sqrt{2}}}{2} \approx 0{,}5412. \end{aligned} \tag{150}$$

Коэффициент C_2:

$$\begin{aligned} C_2 &= \frac{2}{4}\sum_{m=0}^{3} y_m T_2(x_m) = \frac{1}{2}\left(2\cdot\frac{\sqrt{2}}{2} + 1\cdot\left(-\frac{\sqrt{2}}{2}\right) + 3\cdot\left(-\frac{\sqrt{2}}{2}\right) + 0\cdot\frac{\sqrt{2}}{2}\right) \\ &= \frac{1}{2}\left(\sqrt{2} - \frac{\sqrt{2}}{2} - \frac{3\sqrt{2}}{2}\right) = \frac{1}{2}\left(-\sqrt{2}\right) = -\frac{\sqrt{2}}{2} \approx -0{,}7071. \end{aligned} \tag{151}$$

Коэффициент C_3:

$$\begin{aligned} C_3 &= \frac{2}{4}\sum_{m=0}^{3} y_m T_3(x_m) = \frac{1}{2}\left(2\cos\frac{3\pi}{8} + 1\cdot\left(-\cos\frac{\pi}{8}\right) + 3\cdot\cos\frac{\pi}{8} + 0\cdot\left(-\cos\frac{3\pi}{8}\right)\right) \\ &= \frac{1}{2}\left(2\cos\frac{3\pi}{8} + 2\cos\frac{\pi}{8}\right) = \cos\frac{\pi}{8} + \cos\frac{3\pi}{8} = \frac{\sqrt{2+\sqrt{2}}+\sqrt{2-\sqrt{2}}}{2} \approx 1{,}3066. \end{aligned} \tag{152}$$

3. Искомые многочлены наилучшего приближения

Подставляя найденные коэффициенты в формулу (139), получаем:

$$P_0(x) = \frac{3}{2}, \tag{153}$$

$$P_1(x) = \frac{3}{2} + \left(\cos\frac{\pi}{8} - \cos\frac{3\pi}{8}\right)T_1(x) = \frac{3}{2} + \left(\cos\frac{\pi}{8} - \cos\frac{3\pi}{8}\right)x, \tag{154}$$

$$P_2(x) = P_1(x) - \frac{\sqrt{2}}{2}\,T_2(x) = \frac{3}{2} + \left(\cos\frac{\pi}{8} - \cos\frac{3\pi}{8}\right)x - \frac{\sqrt{2}}{2}(2x^2-1), \tag{155}$$

$$\begin{aligned} P_3(x) &= P_2(x) + \left(\cos\frac{\pi}{8} + \cos\frac{3\pi}{8}\right)T_3(x) \\ &= \frac{3}{2} + \left(\cos\frac{\pi}{8} - \cos\frac{3\pi}{8}\right)x - \frac{\sqrt{2}}{2}(2x^2-1) + \left(\cos\frac{\pi}{8} + \cos\frac{3\pi}{8}\right)(4x^3-3x). \end{aligned} \tag{156}$$

Замечание. Поскольку при $n=3$ многочлен $P_3(x)$ имеет степень 3 и строится по 4 узлам, он совпадает с интерполяционным многочленом Лагранжа и точно проходит через все заданные точки. Многочлены P_0, P_1, P_2 дают наилучшее среднеквадратичное приближение среди всех многочленов соответствующей степени.

4. Численная проверка

Для контроля вычислим значения $P_3(x_m)$ и убедимся, что они совпадают с табличными y_m. Например, для $m = 0$:

$$\begin{aligned} P_3(x_0) &= C_0 + C_1 T_1(x_0) + C_2 T_2(x_0) + C_3 T_3(x_0) \\ &= \frac{3}{2} + \left(\cos\frac{\pi}{8} - \cos\frac{3\pi}{8}\right)\cos\frac{\pi}{8} - \frac{\sqrt{2}}{2}\cdot\frac{\sqrt{2}}{2} + \left(\cos\frac{\pi}{8} + \cos\frac{3\pi}{8}\right)\cos\frac{3\pi}{8} \\ &= \frac{3}{2} + \cos^2\frac{\pi}{8} - \cos\frac{\pi}{8}\cos\frac{3\pi}{8} - \frac{1}{2} + \cos\frac{\pi}{8}\cos\frac{3\pi}{8} + \cos^2\frac{3\pi}{8} \\ &= 1 + \cos^2\frac{\pi}{8} + \cos^2\frac{3\pi}{8} = 1 + \frac{1+\cos\frac{\pi}{4}}{2} + \frac{1+\cos\frac{3\pi}{4}}{2} = 1 + \frac{1}{2} + \frac{1}{2} = 2 = y_0. \quad \checkmark \end{aligned} \tag{157}$$

Аналогично проверяются остальные узлы.